Aprendizado de Máquina

Agrupamento de Dados (Hierárquico) e Avaliação de Grupos

Profª Drª Angela Rosa Locateli de Godoy

Agrupamento Hierárquico

- O método foi originalmente **desenvolvido no campo da taxonomia (Biologia)** para classificação dos animais (SOKAL; SNEATH, 1963) antes de se popularizar em outros campos científicos.
- O agrupamento hierárquico **produz uma sequência de partições aninhadas**, ou seja, **os objetos (registros) do conjunto de dados são organizados em grupos** e **subgrupos** de modo **hierárquico.**

São classificados em:

- Aglomerativos
- Divisivos

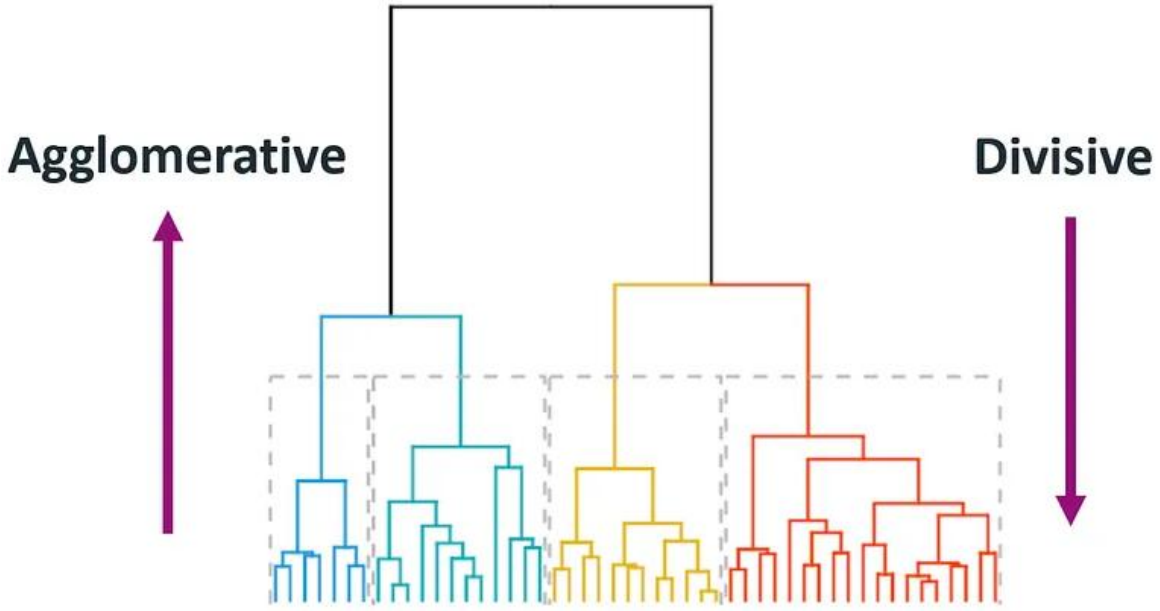

Agrupamento Hierárquico AGLOMERATIVO

- Considera-se, inicialmente, que **cada objeto seja seu próprio grupo**, e a **cada iteração**, os **objetos ou grupos mais parecidos são unidos**, **formando um novo grupo**. Esse processo é repetido até que todos os objetos estejam em um único grupo.

- **Abordagem Bottom-up:** de baixo para cima

- **Algoritmo clássico:** AGNES (*Agglomerative Nesting*)

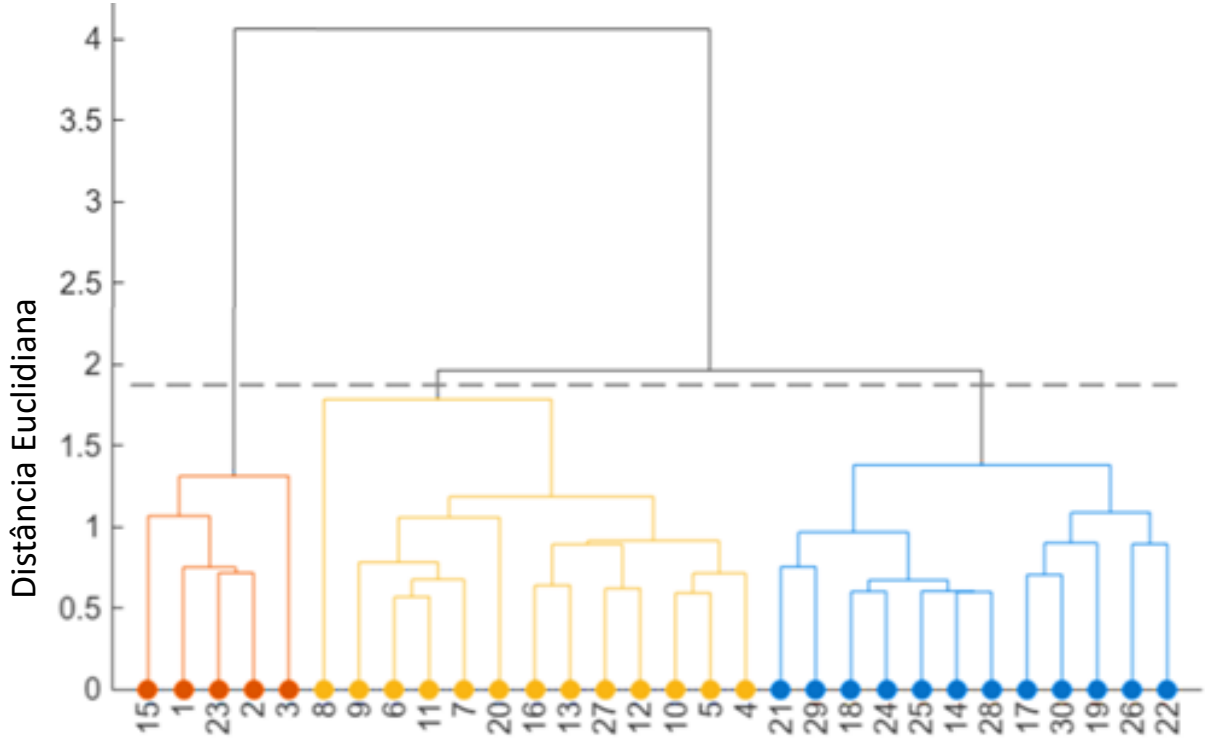

Algoritmo AGNES - Agrupamento Aglomerativo

Entrada: X = {x1,x2,...,xn} : conjunto de objetos do espaço

Saída: S = {P1,P2,...Pk} : conjunto de agrupamentos formados

==========

1. Fazer com que cada objeto x ∈ X seja um grupo;
2. Computar a dissimilaridade entre todos os pares distintos de grupos;
3. Repita

    Selecionar o par de grupos mais próximo;

    Unir os dois grupos para formar um novo grupo G;

    Computar a dissimilaridade entre G e os outros grupos (ou seja, atualizar a matriz de distâncias)

Até obter um único grupo com todos os objetos;

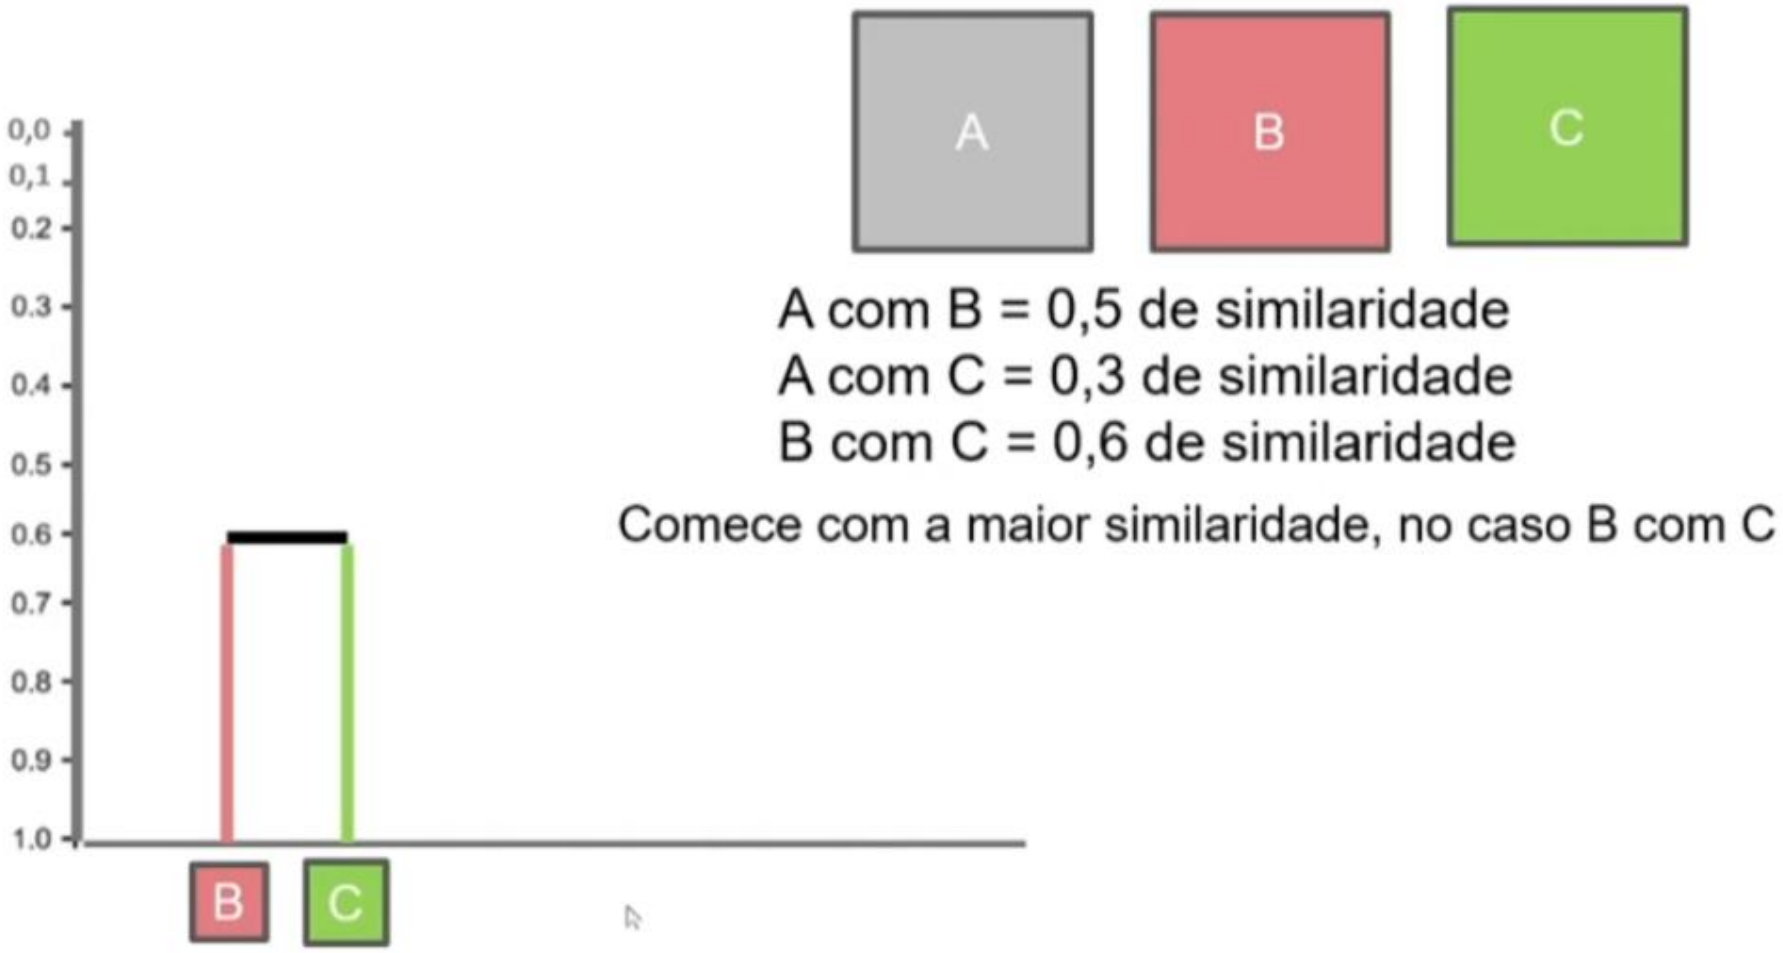

Fonte: https://www.youtube.com/watch?v=FW7sOUOIMm4

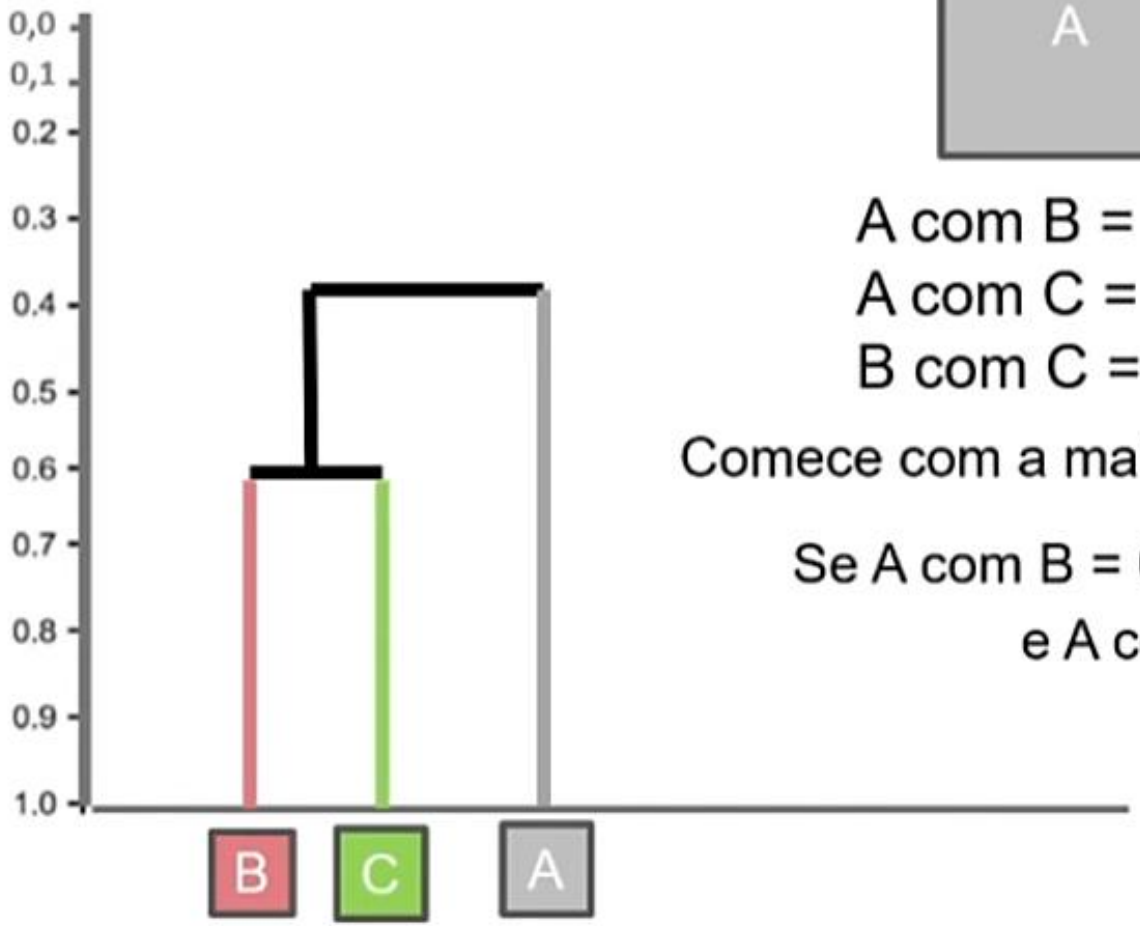

A com B = 0,5 de similaridade
A com C = 0,3 de similaridade
B com C = 0,6 de similaridade

Comece com a maior similaridade, no caso B com C

Se A com B = 0,5
e A com C = 0,3

Então A com Grupo BC =
(0,5+0,3)/2 = 0,4

A com B = 0,5 de similaridade
A com C = 0,3 de similaridade
A com D = 0,8 de similaridade
B com C = 0,6 de similaridade
B com D = 0,4 de similaridade
C com D = 0,3 de similaridade

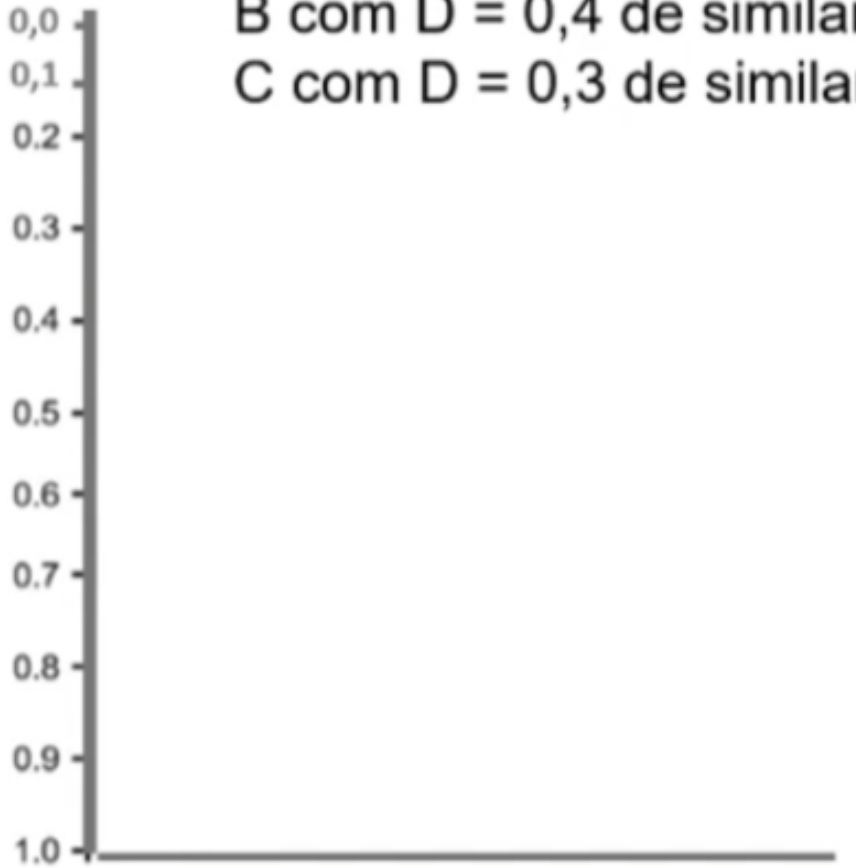

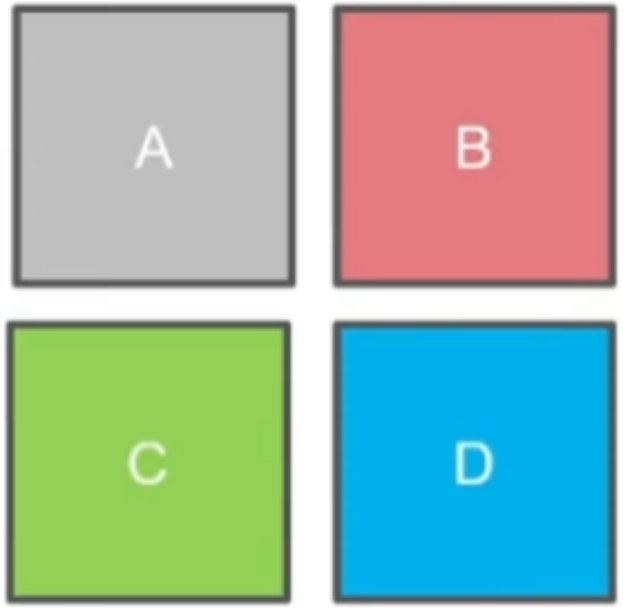

Por onde vocês começariam a fazer o dendrograma de similaridade?

A com B = 0,5 de similaridade
A com C = 0,3 de similaridade
A com D = 0,8 de similaridade
B com C = 0,6 de similaridade
B com D = 0,4 de similaridade
C com D = 0,3 de similaridade

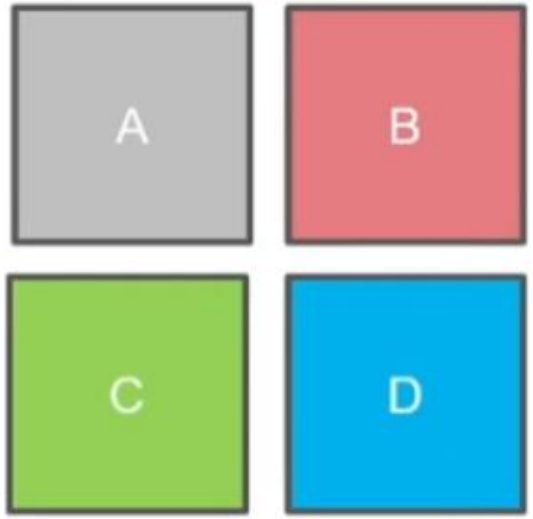

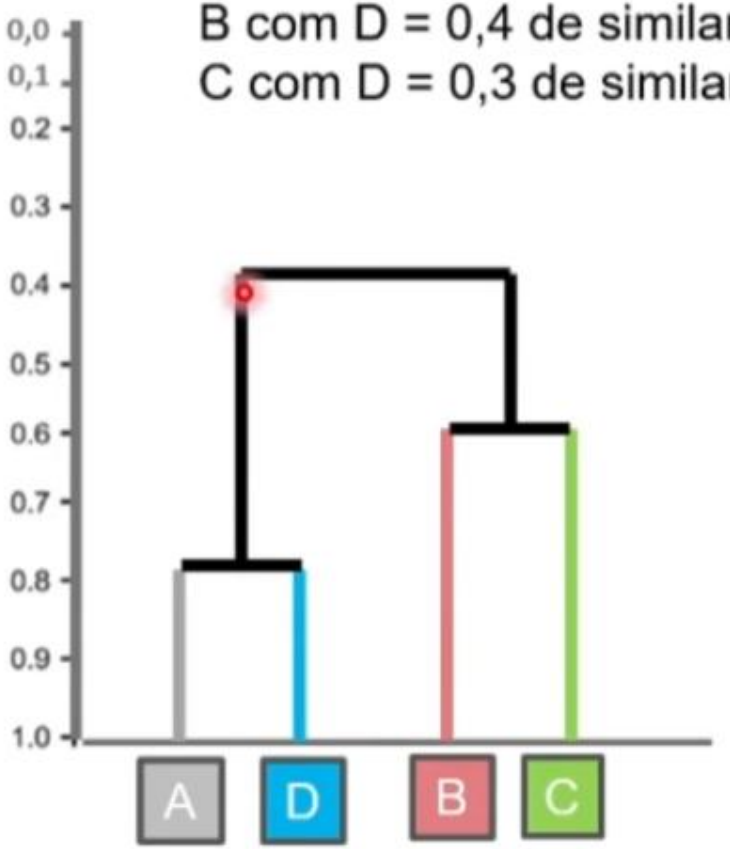

Por onde vocês começariam a fazer o dendrograma de similaridade?

Sempre comece pelas MAIORES SIMILARIDADES... e assim por diante

Neste exemplo, A com D! depois B com C

Agora falta calcular entre os grupos... Neste caso (A com B) + (A com C) + (D com B) + (D com C) dividido por 4...

Matematicamente

$$\frac{(0,5) + (0,3) + (0,4) + (0,3)}{4} \quad \frac{1,5}{4} \quad 0,375$$

Algoritmo AGNES - Agrupamento Aglomerativo

- **Agrupamento aglomerativo hierárquico com uma variável**, no qual **20 amostras** (representadas pelos pontos na parte superior da figura) são **sucessivamente aglomeradas**, par a par, até a formação **de cinco grupos**;
- **Cada etapa** do algoritmo é representada por **uma linha transversal** que corta o dendrograma, e **cada nó** representa uma aglomeração entre amostras e/ou **grupos**.

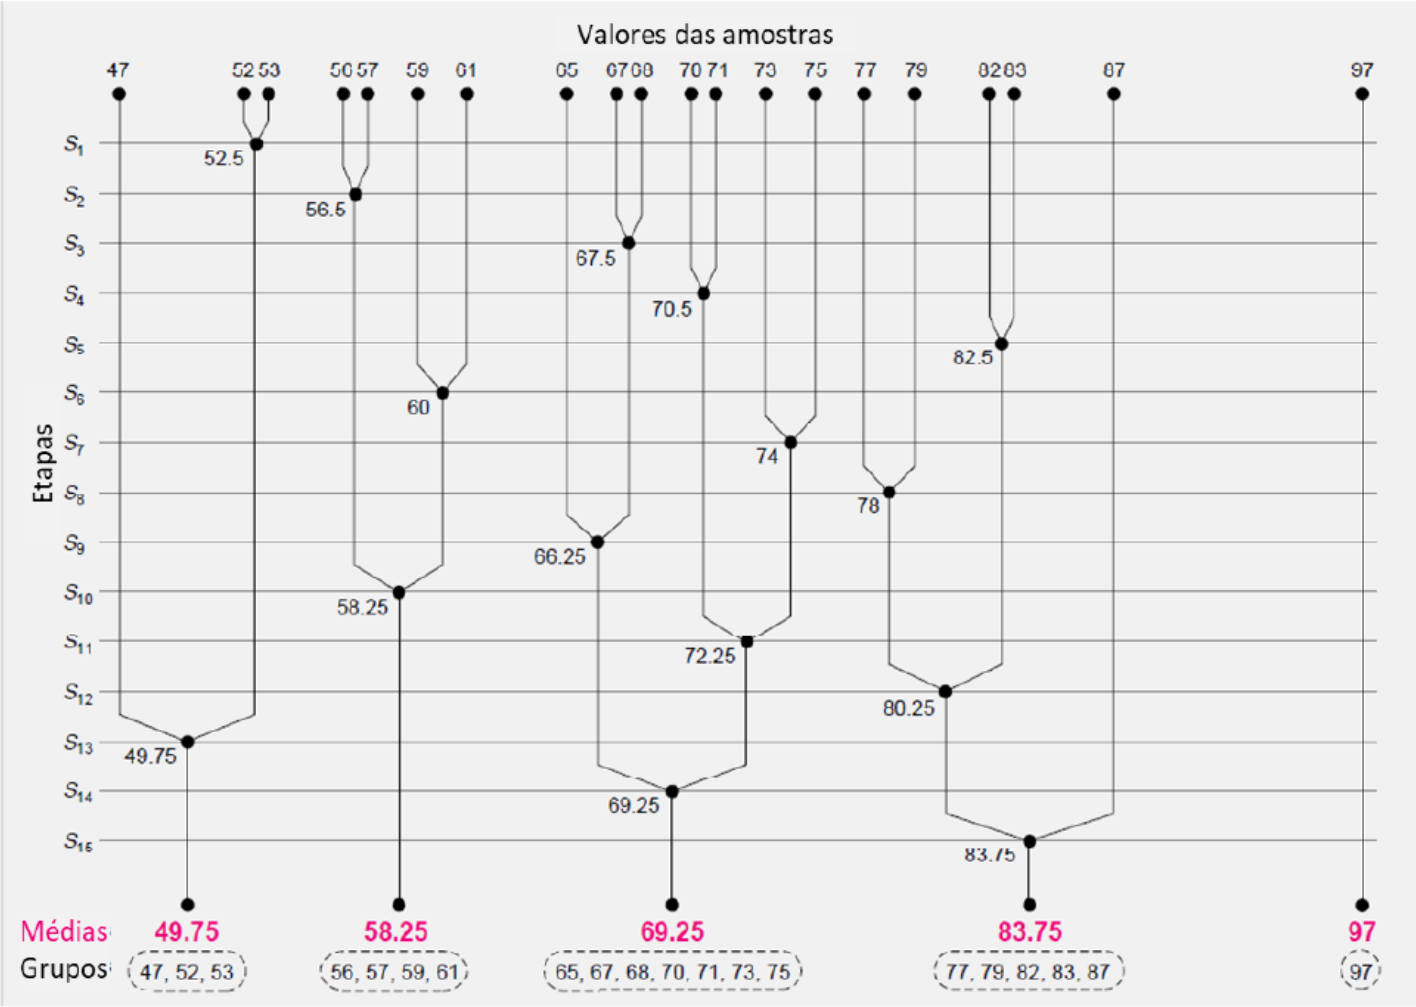

Algoritmos

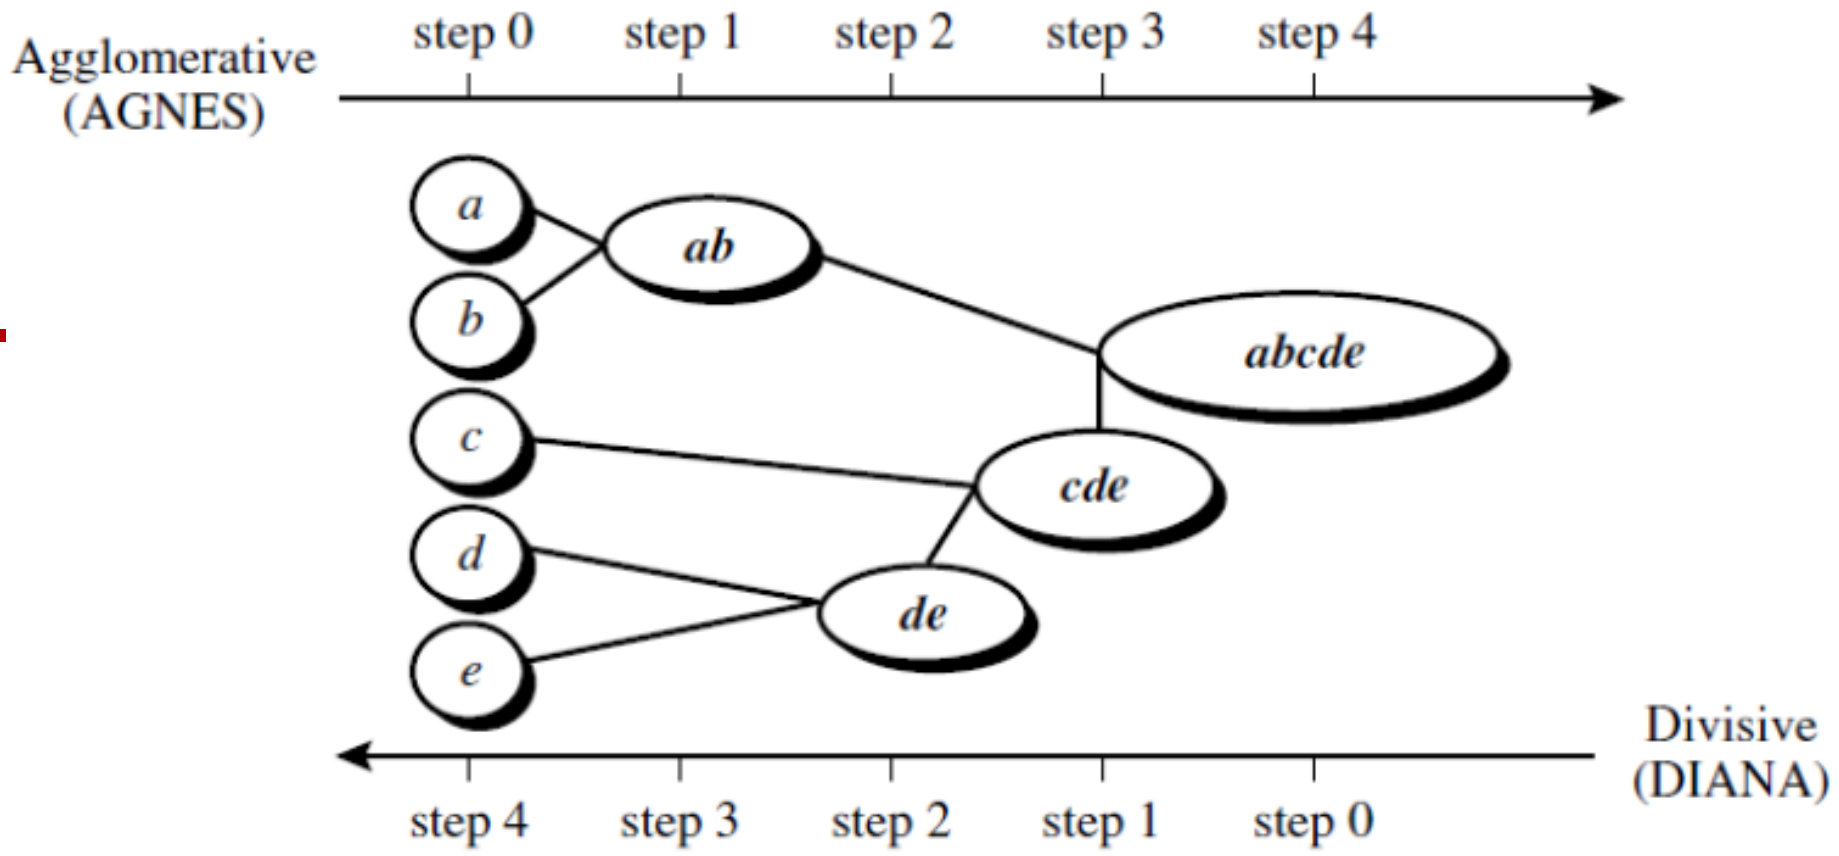

Outros Algoritmos:

- **BIRCH**: Balanced Iterative Reducing and Clustering Using Hierarchies
- **ROCK**: Hierachical Clustering Algorithm for Categorical Attibutes
- **Chameleon:** Hierarchical Custering Algorithm using Dynamic Modeling

Agrupamento Hierárquico DIVISIVOS

- De modo oposto, considera-se que **todos objetos pertencem a um único grupo**, e posteriormente, o **único grupo é dividido até obter-se um grupo para cada objeto** ou até que um critério de parada seja atendido (Han, Pei, and Kamber, 2011).

- **Abordagem Top-down:** de cima para baixo

- **Algoritmo clássico: DIANA**

  ***(Divise Analysis*)**

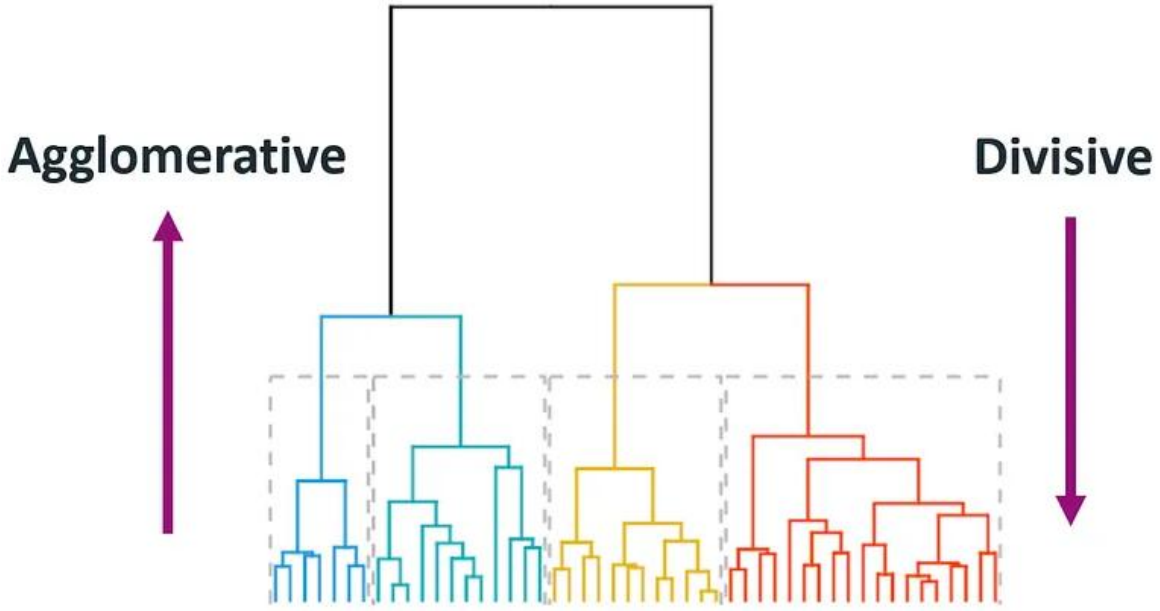

Exemplos

Idade X Salários: https://www.youtube.com/watch?v=Nf-vaOIQA3E

Semelhança entre a característica de leite dos mamíferos:

https://www.youtube.com/watch?v=RoaLQ-REvPI

Dendogramas

Um **dendograma** é frequentemente usado para **representar** um **agrupamento hierárquico**, seja **Aglomerativo ou Divisivo**.

- O **eixo vertical** indica nível de **similaridade**;
- **Eixo horizontal** indica **indivíduos (objetos)**;

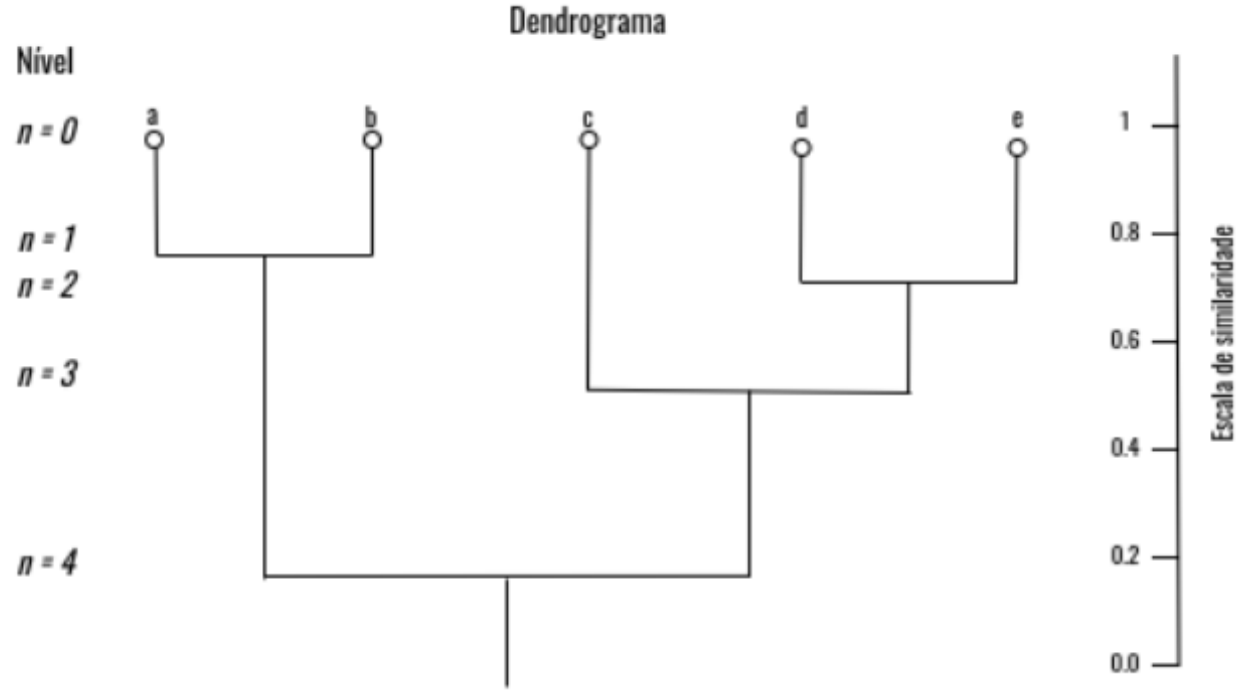

Quanto menor a altura, mais próximos são os objetos do grupo (mais similares entre si)

Dendogramas

- Tanto os métodos **aglomerativos quanto os divisivos organizam os resultados** do agrupamento por meio **dessa árvore binária (dendograma)**;

- **Cada nó** do dendrograma representa **um grupo de objetos**;

- O **dendrograma é um gráfico** em **forma de árvore** onde podemos observar os níveis de similaridade para **as sucessivas etapas do agrupamento**;

- As **linhas verticais partindo dos indivíduos agrupados** têm **altura correspondente ao nível** que os indivíduos são **considerados semelhantes**.

Dendograma

É possível obter uma partição com um **determinado número de grupos**, como nos métodos **particionais**.

Exemplo: a linha tracejada indica uma partição com dois grupos de objetos:

{1, 2, 3} e {4, 5, 6}

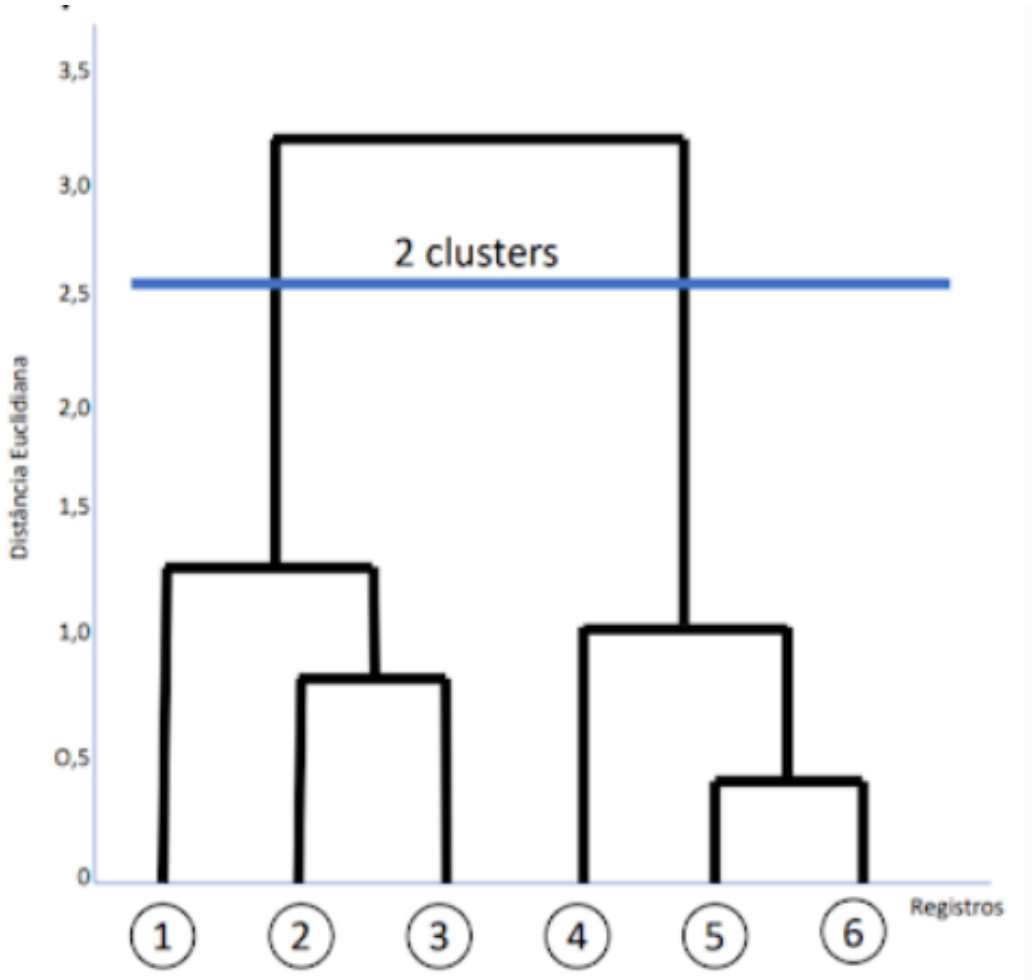

Dendograma - Considerações

- Uma vez que um passo foi feito **(divisão ou união) não pode ser desfeito**.
- Entretanto, essa rigidez **não permite a correção** de possíveis más escolhas;
- Por isso, há a **preocupação em melhorar as escolhas de divisão ou junção** de objetos;
- Essas escolhas são chamadas técnicas de ligações (*linkages*).

Medidas de Avaliação de Grupos

Mede a qualidade de um agrupamento sem utilizar medidas externas aos dados, ou seja, **utilizam as similaridades intra e intergrupos**:

- Medidas de **COESÃO**;
- Medidas de **SEPARAÇÃO**;

Medidas de Avaliação de Grupos

Encontrar **o melhor agrupamento** para um conjunto de objetos **não é uma tarefa simples,** a não ser que *n* (número de objetos) e *k* (número de clusters) **sejam extremamente pequenos**, visto que o número de partições diferentes em que podemos dividir n objetos em k *clusters* é:

$$k^n/k!$$

Exemplo: Se k=2 e n=5 então são 16 formas de dividir 5 elementos em 2 grupos.

Medidas de Avaliação de Grupos

Coesão ou similaridade/dissimilaridade intragrupo

Mede o quanto os **objetos dentro de um grupo se assemelham.**

Como calcular: pela similaridade de cada objeto do grupo ao **centro do cluster, por exemplo.**

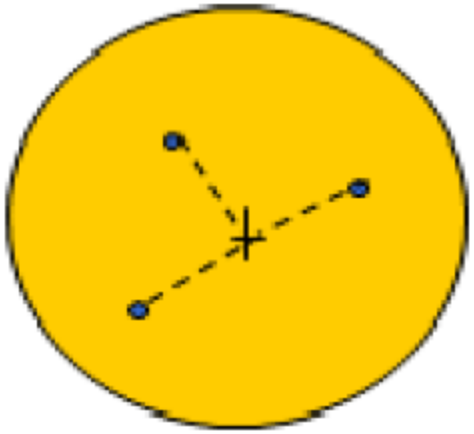

Separação ou similaridade inter-grupos

Mede o quanto **os grupos estão separados entre si**, por exemplo, **a distância entre seus centros**.

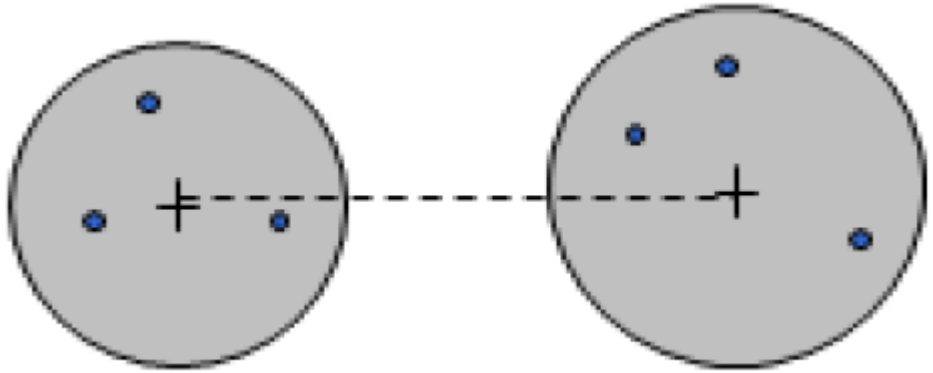

Como definir a quantidade de grupos?

Vamos mostrar dois métodos para definir a quantidade de grupos, sendo eles:

- **Coeficiente de Silhueta**

- **Método do Cotovelo**

Coeficiente de Silhueta

- **Determina o quão bem cada objeto está alocado em um grupo**, ou seja, a **homogeneidade de um grupo**.

- **O índice de Silhueta varia de -1 a 1**.

- Valores **próximos a 1** indicam que o objeto possui **semelhança com objetos de seu grupo** e **dessemelhança** com objetos de **outros grupos**.

- O **número ideal de grupos** é escolhido **com base na maior média do índice de Silhueta**.

Coeficiente de Silhueta

Valores negativos não desejados:

Distância média de *xi* a objetos de seu grupo é maior que a distância média de *xi* a um outro grupo ao qual *xi* não pertence

$$s(x_i) = (b(x_i) - a(x_i)) / \max\{a(x_i), b(x_i)\}$$

Coeficiente de silhueta mais próximo de 1 garante maior qualidade do agrupamento.

O coeficiente de silhueta também é métrica de avaliação escolhido para determinar qual dos algoritmos seria melhor, por exemplo, *K-means ou K-medoids.*

Coeficiente de Silhueta

Valor de silhueta de um objeto: diz quão bem esse objeto está quando colocado neste grupo

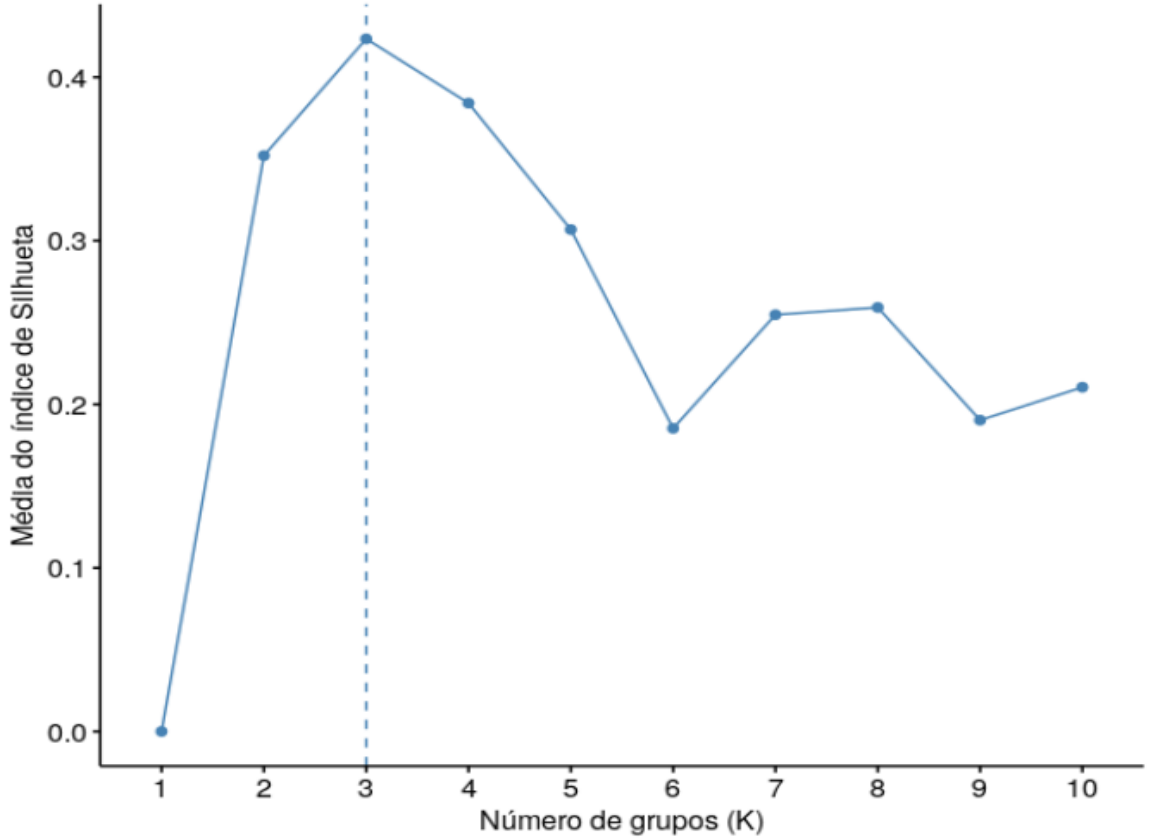

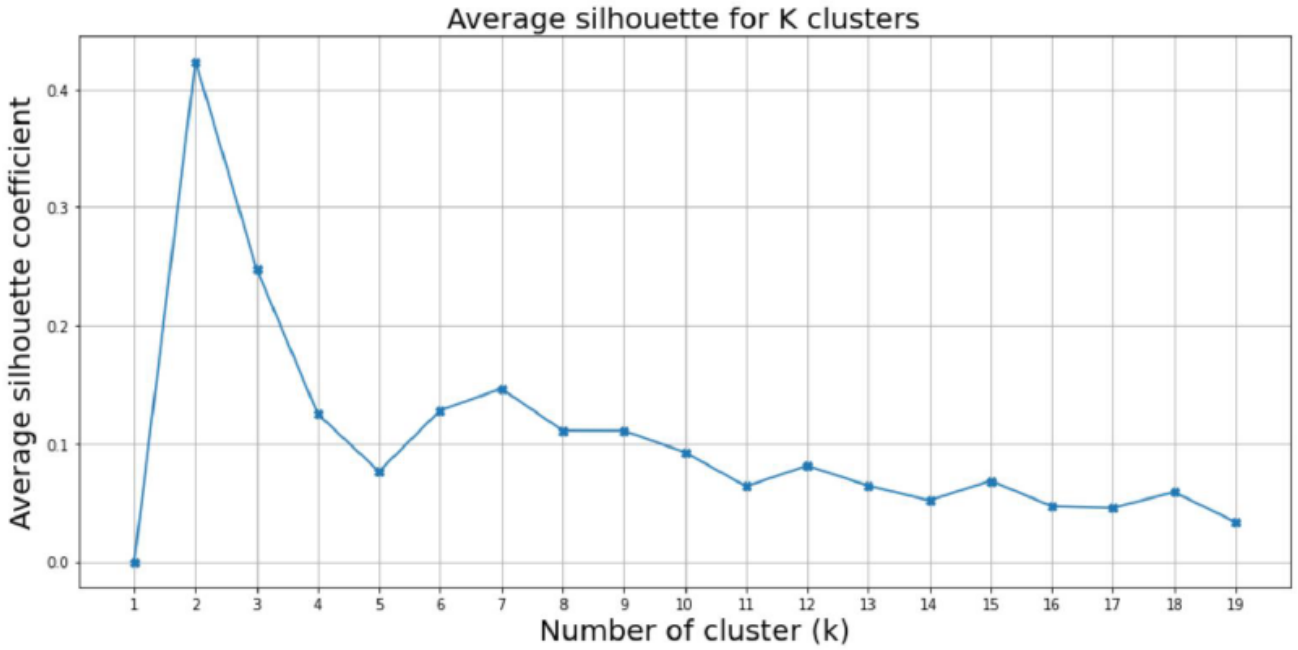

Coeficiente de Silhueta

Como calcular

- Dada uma coleção de *n* objetos *X = {x1,...,xn},* o valor de Silhueta *s(xi)* do objeto *xi* é obtido pela equação a seguir:

$$s(x_i) = (b(x_i) - a(x_i)) / \max\{a(x_i), b(x_i)\}$$

(xi): **distância média entre *xi* e todos os objetos** do seu grupo; (**COESÃO**)

b(xi): **distância média entre *xi* e um outro grupo** ao qual xi não pertence **(SEPARAÇÃO)**

Coeficiente de Silhueta

- Com os **valores de Silhueta de cada objeto pode-se calcular o valor global de silhueta de uma partição** p(Sp) por meio da média dos valores de silhueta:

$$S_p = \sum_{i=1}^{n} s(xi)/n$$

- Sendo *s(xi)* o coeficiente de silhueta do objeto *i* e *n* o número de objetos do conjunto (partição).

Método do cotovelo

- O **número ideal de grupos** se dá quando **o ponto forma uma curva** semelhante de um **cotovelo**, que é o ponto considerado ideal.
- Pois os pontos acima do cotovelo estão em uma região de *underfitting* e abaixo dele em *overfitting*.

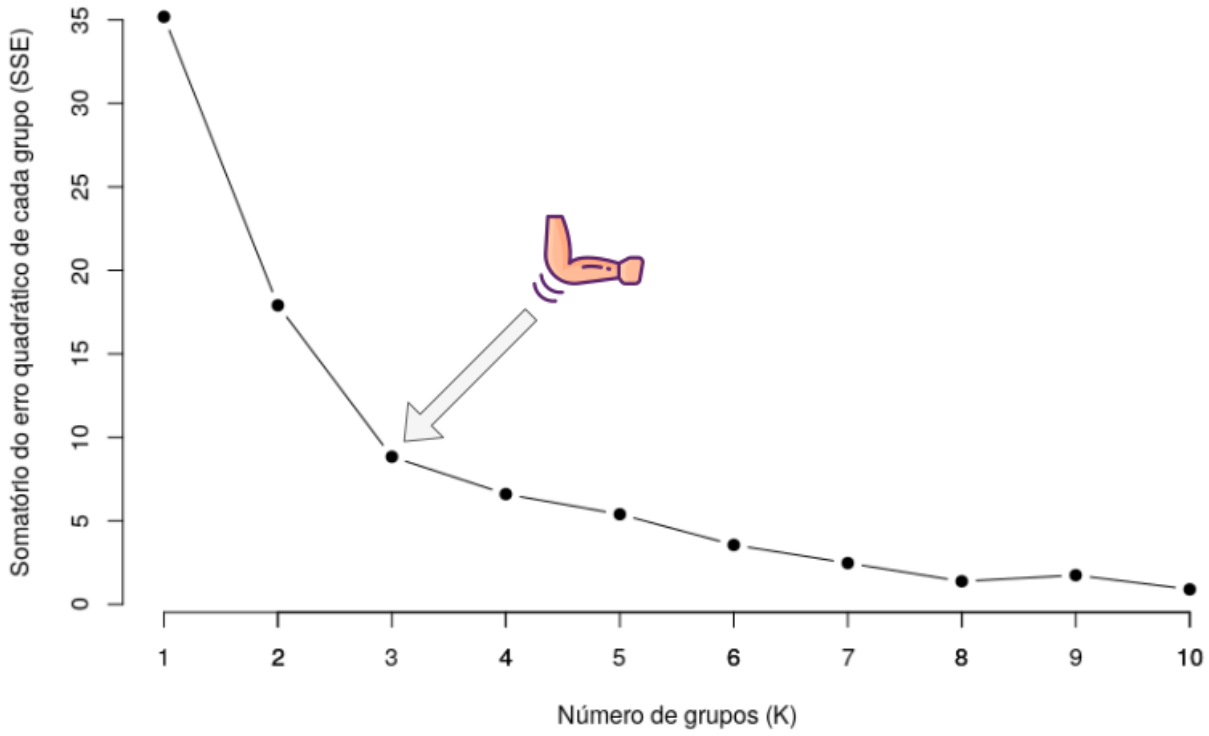

Método do cotovelo

- O método do cotovelo **usa o somatório do erro total dos grupos** em cada agrupamento **para determinar o número de K**.
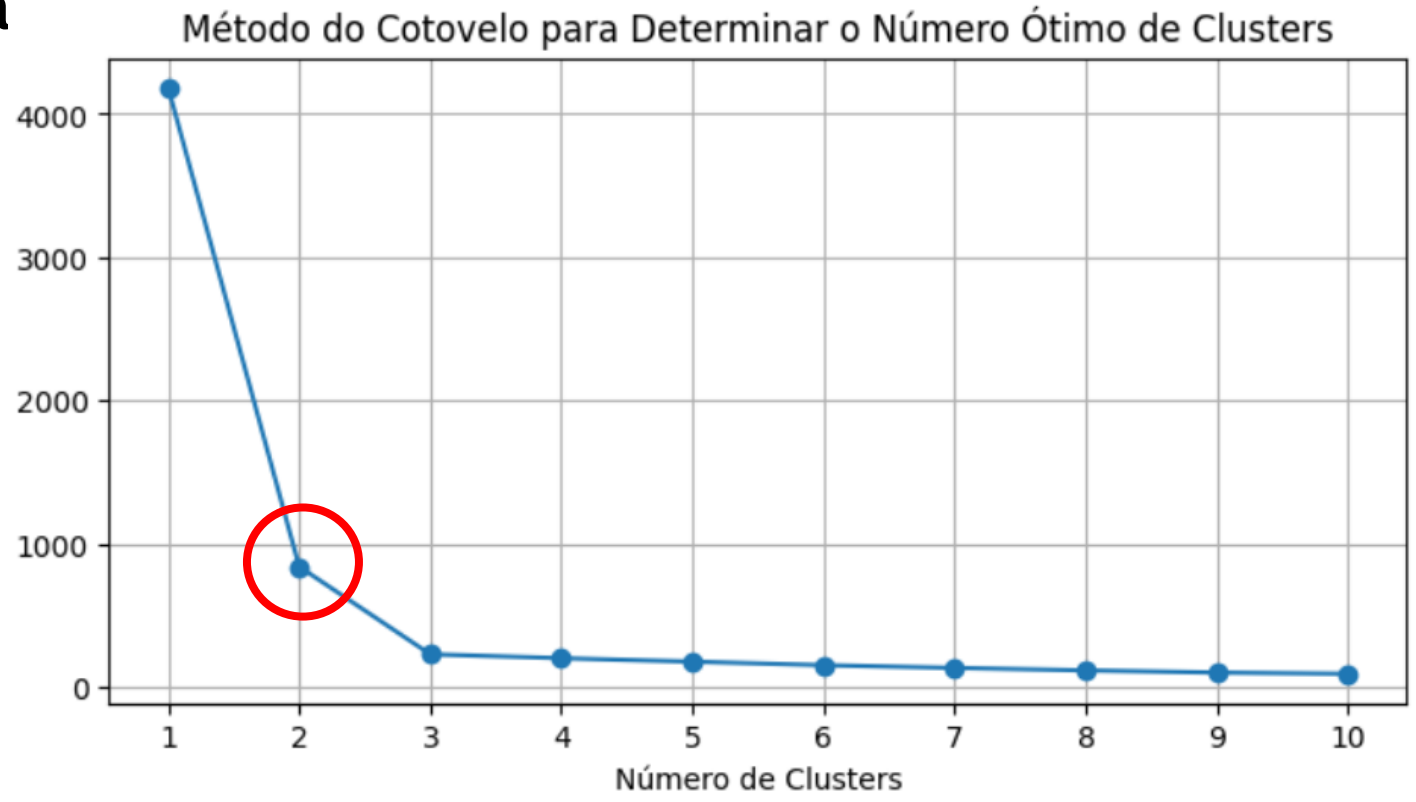
- A ideia deste método é **gerar diversos agrupamentos com diferentes números de grupos**, com o **incremento do número de grupos**, o **erro total tende a diminuir**, até que o erro se **aproxime de zero**, que é quando terá um objeto por grupo.