Mineração de Dados

Regras de Associação

Profª Drª Angela Rosa Locateli de Godoy

Regra de Associação

- Ao descobrir **associações entre dados, tal como vendas, descobre-se regras de associação**. Em um conjunto de dados, pode-se descobrir quando **os dados se associam com frequência.**
- No caso da venda, a **venda de um produto pode induzir a venda de outro produto.**
- Por exemplo, **quantas vezes a venda de café induz a venda de açúcar**, e quantas vezes a **venda de café e açúcar induz** a venda de **leite**.

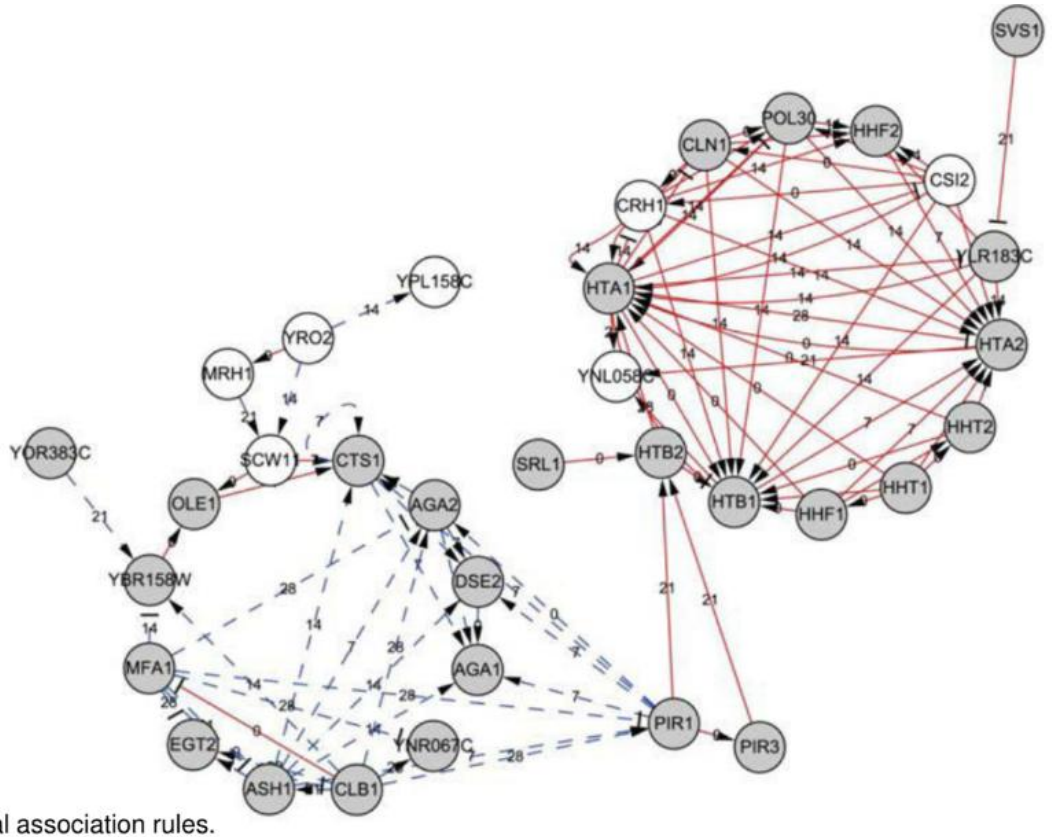

Extraído de Temporal association rules.
Nam et al. BMC Bioinformatics 2009 10(Suppl 3):S6

Definição

As bases de dados compartilham uma propriedade comum: **todas elas são formadas por registros (objetos) caracterizados por atributos**.

Por exemplo:

ID	BI-RADS	Idade	Forma	Contorno	Densidade	Severidade
1	5	67	Lobular	Especulada	Baixa	Maligno
2	4	43	Redonda	Circunscrita	Baixa	Maligno
3	5	58	Irregular	Especulada	Baixa	Maligno
4	4	28	Redonda	Circunscrita	Baixa	Maligno

Bases de Dados Transacionais

Existe outro tipo de base de dados, muito comum em alguns ambientes empresariais, **que relaciona conjuntos de itens que ocorrem em transações.**

Exemplo típico quando alguém vai ao supermercado, faz uma compra e passa na caixa registradora.

Constantemente, a navegação na web é armazenada pelas lojas, buscadores e até empresas especializadas nessa tarefa, e utilizada para campanhas de marketing comportamental e vendas casadas, entre outras.

Bases Transacionais como Binárias

TID	ITENS
1	{**Leite**, **pão**, açúcar, café, manteiga}
2	{Mamão, banana, maçã}
3	{**Leite**, **pão**}
4	{**Leite**, **pão**, manteiga, banana}

TID	Leite	Pão	Açúcar	Café	Manteiga	Mamão	Banana	Maçã
1	1	1	1	1	1	0	0	0
2	0	0	0	0	0	1	1	1
3	1	1	0	0	0	0	0	0
4	1	1	0	0	1	0	1	0

Regras de Associação

- As **bases transacionais** podem ser analisadas em **busca de relações entre seus itens**.
- No caso do exemplo anterior, é possível afirmar que sempre que alguém **compra leite, também compra pão**, o que pode ser representado pela seguinte regra:

{Leite} → {Pão} (Leia-se “leite implica pão”)

Conceitos importantes

Itemset: conjunto de itens (atributos).

Exemplos:

{a, b, c}

{1,2,3}

{leite, pão, açúcar, manteiga}

{André, Marcio, Marcos}

Regra de Associação – Definição

Seja **A** uma Base de Dados composta por um conjunto de itens:

$$\mathbf{A = \{a_1, a_2, \ldots, a_m\}}$$

e por um conjunto de transações:

$$\mathbf{T = \{t_1, t_2, \ldots, t_n\},}$$

TID	Itens
1	{Leite, pão, açúcar, café, manteiga}
2	{Mamão, banana, maçã}
3	{Leite, pão}
4	{Leite, pão, manteiga, banana}

em que, cada transação $\mathbf{t_i}$ é composta por um conjunto de itens tal que $\mathbf{t_i}$ está contido em **A**.

Regra de Associação

Considere a base de dados de transações a seguir:

Uma regra de associação é uma implicação da forma (**X** → **Y**), onde X e Y são conjuntos de itens)

X → Y

{Leite, Pão} → {Manteiga}

(Leia-se "leite implica pão")

{Leite} → {Pão}

Conjuntos de itens

Antecedente da Regra

Consequente da Regra

Regra de Associação

- Essa regra é considerada uma **regra forte** em virtude da elevada relação de **coocorrência entre os itens**.
- Nesse caso, a **coocorrência entre os itens** é a situação em que dois ou mais itens aparecem **juntos na mesma transação.**

TID	Itens
1	{Leite, pão, açúcar, café, manteiga}
2	{Mamão, banana, maçã}
3	{Leite, pão}
4	{Leite, pão, manteiga, banana}

R1: {Leite} → {Pão}

Um item SEMPRE implica a ocorrência do outro.

Regra de Associação

- Assim, as **regras de associação** podem ser vistas como **padrões descritivos**.
- Representam a **probabilidade de que um conjunto de itens apareça em uma transação**, dado que outro conjunto esta presente.

Exemplo:

R1: {Leite} → {Pão}

R2: {Leite, Pão} → {Manteiga}

TID	Itens
1	{Leite, pão, açúcar, café, manteiga}
2	{Mamão, banana, maçã}
3	{Leite, pão}
4	{Leite, pão, manteiga, banana}

Qual a probabilidade do cliente comprar leite e pão?

E comprar manteiga, dado que comprou leite e pão?

Algoritmo *Apriori*

Database D

TID	Itens
100	1 3 4
200	2 3 5
300	1 2 3 5
400	2 5

Scan D

C_1

itemset	Sup.
{1}	2
{2}	3
{3}	3
{4}	1
{5}	3

L_1

Itemset	Sup.
{1}	2
{2}	3
{3}	3
{5}	3

C_2

itemset
{1 2}
{1 3}
{1 5}
{2 3}
{2 5}
{3 5}

Scan D

C_2

itemset	Sup.
{1 2}	1
{1 3}	2
{1 5}	1
{2 3}	2
{2 5}	3
{3 5}	2

L_2

itemset	Sup.
{1 3}	2
{2 3}	2
{2 5}	3
{3 5}	2

C_3

itemset
{2 3 5}

Scan D

L_3

itemset	Sup.
{2 3 5}	2

Suporte e Confiança

Como uma **grande quantidade de regras de associação** pode ser derivada a partir de uma base de dados, mesmo que pequena, normalmente se objetiva **a derivação de regras que suportem um grande número de transações e** que possuam uma **confiança razoável para as transações as quais elas são aplicáveis**.

Esses requisitos estão associados a dois conceitos centrais em mineração de regras de associação: Suporte e Confiança

Suporte

- O suporte, ou cobertura, de uma regra de associação é o **número de transações** para as quais **os *itemsets* desejados aparecem na base de transações**.
- Também pode ser entendida como a **utilidade de uma dada regra.**

Qual a probabilidade do cliente comprar leite e pão?
E comprar manteiga, dado que comprou leite e pão?

TID	Itens
1	{Leite, pão, açúcar, café, manteiga}
2	{Mamão, banana, maçã}
3	{Leite, pão}
4	{Leite, pão, manteiga, banana}

Suporte

O suporte de uma regra é medido *pela razão entre:*

O número de transações que contém um *itemset* em particular e, pelo número de transações da base.

Formalmente, o suporte pode ser descrito pela fórmula:

$$suporte\ (X \rightarrow Y) = \frac{sup(X \cup Y)}{|N|}$$

Sendo X o conjunto de itens presentes no antecedente da regra, Y o conjunto de itens presentes no consequente da regra e, N, o número de transações.

Exemplo Suporte

- Para ilustrar esses dois conceitos, considere a regra {Leite} → {Pão} apresentada anteriormente.
- Essa regra ocorre em três das quatro transações apresentadas, o que faz com que seu **suporte seja alto, igual a 75%.**

TID	Itens
1	{Leite, pão, açúcar, café, manteiga}
2	{Mamão, banana, maçã}
3	{Leite, pão}
4	{Leite, pão, manteiga, banana}

R1: {Leite} → {Pão}
R1: 3/4 **= 75%**

R2: {Leite, Pão} → {Manteiga}
R2: 2/4 **= 50%**

Exemplo de Suporte

A regra **{Leite, Manteiga}** → **{Banana}**

Tem suporte de 25%

(os três itens aparecem juntos em uma transação, dentre as quatro possíveis).

TID	Itens
1	{Leite, pão, açúcar, café, manteiga}
2	{Mamão, banana, maçã}
3	{Leite, pão}
4	{Leite, pão, manteiga, banana}

Confiança

Determina a frequência com que o **consequente da regra (Y)** aparece em transações que contém **o antecedente** (X) também pode ser entendida como a certeza de uma dada regra.

A confiança de uma regra X→Y mede a confiabilidade, ou precisão, da inferência feita pela regra.

Ela determina a frequência com que o consequente da regra Y aparece em transações que contém o antecedente X.

A confiança é descrita pela seguinte fórmula:

$$confiança\ (X \rightarrow Y) = \frac{suporte(X \cup Y)}{suporte(X)}$$

Exemplo de Confiança

Considere a regra {Leite, Manteiga} → {Banana}

Qual sua confiança?

TID	Itens
1	{Leite, pão, açúcar, café, manteiga}
2	{Mamão, banana, maçã}
3	{Leite, pão}
4	{Leite, pão, manteiga banana}

$$confiança\ (X \rightarrow Y) = \frac{suporte(X \cup Y)}{suporte(X)} = (1/4)/(2/4) = 0{,}5$$

Em 50% das vezes em que banana ocorre na base, o antecedente da regra é composto por leite e manteiga.

Exemplo aplicado

Regra de Associação:

- Uma implicação da forma **X** → **Y**, onde **X** e **Y** são conjuntos frequentes.
- **Exemplo:** {Leite, Fralda} → {Cerveja}

TID	ITENS
1	{Pão, Leite}
2	{Pão, Fralda, Cerveja, Ovos}
3	{**Leite, Fralda, Cerveja**, Coca}
4	{Pão, **Leite, Fralda, Cerveja**}
5	{Pão, Leite, Fralda, Coca}

Exemplo aplicado

Suporte?

Confiança?

TID	ITENS
1	{Pão, Leite}
2	{Pão, Fralda, Cerveja, Ovos}
3	{**Leite, Fralda, Cerveja**, Coca}
4	{Pão, **Leite, Fralda, Cerveja**}
5	{Pão, Leite, Fralda, Coca}

- **R1**: {Pão} → {Leite}
- **R2**: {Leite, Fralda} → {Cerveja}
- **R3**: {Leite, Pão} → {Fralda, Coca}

Exemplo aplicado

Regra: {Leite, Fralda} -> {Cerveja}

TID	ITENS
1	{Pão, Leite}
2	{Pão, Fralda, Cerveja, Ovos}
3	{**Leite, Fralda, Cerveja**, Coca}
4	{Pão, **Leite, Fralda, Cerveja**}
5	{Pão, Leite, Fralda, Coca}

$$Sup = \frac{\text{Freq (Leite, Fralda, Cerveja)}}{|T|} = \frac{2}{5}$$

$$Conf = \frac{\text{Freq (Leite, Fralda, Cerveja)}}{\text{Freq (Leite, Fralda)}} = \frac{2}{3}$$

R1: {Pão} → {Leite}

TID	ITENS
1	{Pão, Leite}
2	{Pão, Fralda, Cerveja, Ovos}
3	{**Leite, Fralda, Cerveja**, Coca}
4	{Pão, **Leite, Fralda, Cerveja**}
5	{Pão, Leite, Fralda, Coca}

- **Suporte:**

  Transações com **Pão e Leite juntos**: T1, T4, T5 → **3**

  Total de transações: **5**

  Suporte: $$\frac{3}{5} = 0{,}6\ (60\%)$$

- **Confiança:**

  Transações com **Pão e Leite juntos**: T1, T4, T5 → **3**

  Transações como antecedente **Pão**: T1, T2, T4, T5 → **4**

  Confiança: $$\frac{3}{4} = 0{,}75\ (75\%)$$

TID	ITENS
1	{Pão, Leite}
2	{Pão, Fralda, Cerveja, Ovos}
3	{**Leite, Fralda, Cerveja**, Coca}
4	{Pão, **Leite, Fralda, Cerveja**}
5	{Pão, Leite, Fralda, Coca}

R2: {Leite, Fralda} → {Cerveja}

- **Suporte:**

  Transações com **Leite, Fralda e Cerveja**: T3, T4 → **2**

  Total de transações: **5**

  Suporte $\frac{2}{5} = 0{,}4\ (40\%)$

- **Confiança:**

  Transações com **Leite, Fralda e Cerveja**: T3, T4 → **2**

  Transações com **Leite e Fralda juntos**: T3, T4, T5 → **3**

  Confiança: $\frac{2}{3} \approx 0{,}67\ (66{,}7\%)$

TID	ITENS
1	{Pão, Leite}
2	{Pão, Fralda, Cerveja, Ovos}
3	{**Leite, Fralda, Cerveja**, Coca}
4	{Pão, **Leite, Fralda, Cerveja**}
5	{Pão, Leite, Fralda, Coca}

R3: {Leite, Pão} → {Fralda, Coca}

- **Suporte:**

  Transações com **todos os itens (Leite, Pão, Fralda, Coca)**: T5 → **1**

  Total de transações: **5**

  Suporte:

$$\frac{1}{5} = 0{,}2\ (20\%)$$

- **Confiança:**

  Transações com **todos os itens (Leite, Pão, Fralda, Coca)**: T5 → **1**

  Transações com **Leite e Pão**: T1, T4, T5 → **3**

  Confiança:

$$\frac{1}{3} \approx 0{,}33\ (33{,}3\%)$$

Regra	Suporte	Confiança
R1	0,60	0,75
R2	0,40	0,67
R3	0,20	0,33

Suporte e Confiança mínimos

Dado um conjunto de transações, o problema de minerar regras de associação corresponde a encontrar todas as regras que satisfazem:

- **Minsup:** valor mínimo de suporte e;
- **Minconf:** valor mínimo de confiança.