UNICAMP

Faculdade de Tecnologia

FACULDADE DE TECNOLOGIA

Estudo da Poluição Atmosférica com Análise de Clusters de Material Particulado

A. R. L. GODOY

M. C. BUENO

Introdução e Principais Conceitos

Organização Mundial da Saúde

Nove em cada dez pessoas respiram ar poluído e contaminado. (Relatório Anual da OMS, 2018)

Todos os anos morrem sete milhões de pessoas por causas diretamente relacionadas com a poluição do ar e os níveis de contaminação permanecem elevados. (WHO World Health Organization,2018)

CONSELHO NACIONAL DO MEIO AMBIENTE
CONAMA

Padrões de qualidade do ar (base na OMS) - Resolução 491/2018

CETESB
Companhia Ambiental do Estado de São Paulo

Os principais poluentes atmosféricos são (CETESB, 2018):

- Partículas Inaláveis Finas ($MP_{2,5}$)
- Partículas Inaláveis (MP_{10}) e Fumaça
- Monóxido de Carbono (CO)
- Dióxido de Nitrogênio (NO_2)
- Dióxido de Enxofre (SO_2)
- Ozônio (O_3)

Introdução e Principais Conceitos

- **Partículas Inaláveis Grossas: MP_{10} (de 2,5 a 10 µm)**

  Filtradas ao nível de nariz e das vias respiratórias superiores

- **Partículas Inaláveis Finas: MP2,5 (<2,5 µm)**

  Penetram profundamente no sistema respiratório, alcançam os alvéolos pulmonares e corrente sanguínea causando doenças como derrames cerebrais, ataques de coração, obstruções pulmonares e infecções respiratórias.

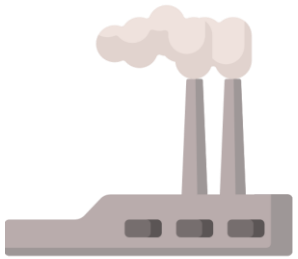

Fontes emissoras: veículos, indústrias, usinas, queimas em geral, fontes naturais, como vulcões, poeiras das ruas pelos ventos e veículos, carregam substâncias tóxicas e cancerígenas que potencializam efeitos danosos no meio ambiente e saúde. (YANAGI, 2010)

Valores recomendados – $MP_{2,5}$
Média anual: 20µg/m³ e Para 24h: 60µg/m³

CONSELHO NACIONAL DO MEIO AMBIENTE
CONAMA

Trabalhos Relacionados

OBJETIVO: Analisar a **base de dados Qualar**, aplicando **algoritmos de Agrupamentos e Regras de Associação** para geração de conhecimento não explícito, **relacionados às partículas inaláveis finas $MP_{2,5}$.**
Investigar a poluição do ar, que acarretam problemas respiratórios e outros prejuízos à saúde.

EUA

Agrupamento por locais de acordo com $MP_{2,5}$.

Resultado: obteve clusters por regiões e atividade industrial desenvolvida. (AUSTIN, 2013)

BRASIL

1. **Material particulado fino** estimado por modelo matemático e **internações por pneumonia e asma** em crianças. (MACHIN, 2018)

Resultado: incremento de $MP_{2,5}$ contribui para até 38% de internações.

2. Relação entre os índices MP_{10} e $MP_{2,5}$, variam durante o ano, em decorrência de umidade e velocidade do vento, por atividades industriais ou emissões de tráfego associados. (NOGAROTTO, 2019)

CHINA

Agrupamentos de 13 locais baseado em $MP_{2,5}$

Resultado: 3 clusters, 2 com atividades industriais de alta tecnologia e 1 com atividades agrícolas e turísticas. (MARTINS, 2019)

Metodologia

Duas etapas: Agrupamento e Regras de Associação

Base de dados:

- Monitoramento SP: 22 UGRHIs
- Período: 24 meses – 24 colunas
  01/01/2017 a 31/12/2018
- 21 cidades monitoram $MP_{2,5}$: 21 tuplas

Pré-processamento:

- Valores faltantes – imputação direta: Inserido o mesmo valor do mês, só que de ano distinto.
- Normalização: Z-Score

Cada coluna é um mês captado pelo sistema Qualar.

Metodologia

Duas etapas: Agrupamento e Regras de Associação

Agrupamento:

- Escolha do Algoritmo: *K-Means* e *K-Medoids*
- Qualidade do Agrupamento: Coeficiente de Silhueta
- Implementação: *Linguagem Python*
- Bibliotecas "*Scikit-learn*" e "*Pyclustering*"
- Distância euclidiana para medir a similaridade

Metodologia

Duas etapas: Agrupamento e Regras de Associação

Agrupamento:

- Escolha do Algoritmo: *K-Means* e *K-Medoids*
- Qualidade do Agrupamento: Coeficiente de Silhueta
- Implementação: *Linguagem Python*
- Bibliotecas "*Scikit-learn*" e "*Pyclustering*"
- Distância euclidiana para medir a similaridade

1

Valor médio da Silhueta, após 100 execuções.

K-means	*K-medoid*
0,26	**0,30**

Metodologia

Duas etapas: Agrupamento e Regras de Associação

Agrupamento:

- Escolha do Algoritmo: *K-Means* e *K-Medoids*
- Qualidade do Agrupamento: Coeficiente de Silhueta
- Implementação: Linguagem *Python*
- Bibliotecas "*Scikit-learn*" e "*Pyclustering*"
- Distância euclidiana para medir a similaridade

1

Valor médio da Silhueta, após 100 execuções.

K-means	*K-medoid*
0,26	0,30

2

Nº de k *cluster* por valor médio do coeficiente de silhueta.
Obtido a partir do algoritmo *k-medoid*.

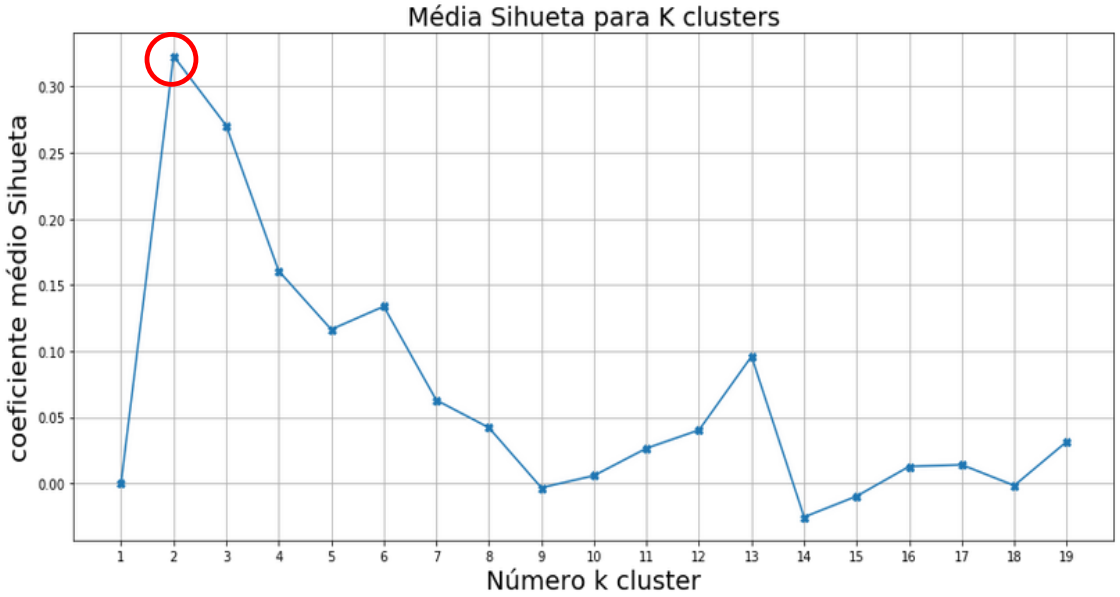

Regras de Associação:

- 1- Buscar valores (sistema Qualar) Mínimos, Máximo e Médias Mensais (2017 - 2018) de: Umidade Relativa do ar, Temperatura, Velocidade do Vento e CO

- 2- Obter as Médias Mensais de 2017 e 2018 das Cidades que monitoram MP2,5

- 3- Da etapa anterior obter apenas os meses de maiores concentrações (2017-2018) (seção resultados)

1	cidade	set_2017_CO	Jul_2018_CO	set_2017_TEMP	Jul_2018_TEMP	set_2017_UR	Jul_2018_UR	set_2017_VV	Jul_2018_VV
2	Marg.Tietê-Pte	0,8	1,1	22,0	19,1	57	62	2,0	1,6
3	S.Bernardo-Centro	0,5	0,8	19,7	16,2	75	76	1,8	1,5
4	Guarulhos-Pimentas	0,6	0,7	20,8	17,8	62	70	2,1	1,5

Regras de Associação:

- 4- Transformação da base do item 3 em 2 bases Transacionais binarias (2017 / 2018)

- Exemplo:

TID	Leite	Pão	Açúcar	Café	Manteiga	Mamão	Banana	Maçã
1	1	1	1	1	1	0	0	0
2	0	0	0	0	0	1	1	1
3	1	1	0	0	0	0	0	0
4	1	1	0	0	1	0	1	0

Fragmento da base de dados transacionais (2017), relacionando as cidades de monitoradas.

Cidade	CO (2017) >=0.4 (média)	CO (2017) <= 0.4 (média)	CO (2017) >= 1,3 (máxima)
Parque D.Pedro II	1	0	0
Pinheiros	1	0	0

- Implementação: Linguagem Python
- Algoritmo Apriori , com biblioteca "Mlxtend".

Resultados e Discussões

- Implementação: Linguagem *Python*
- Algoritmo *"Scikit-lear"*

Agrupamento

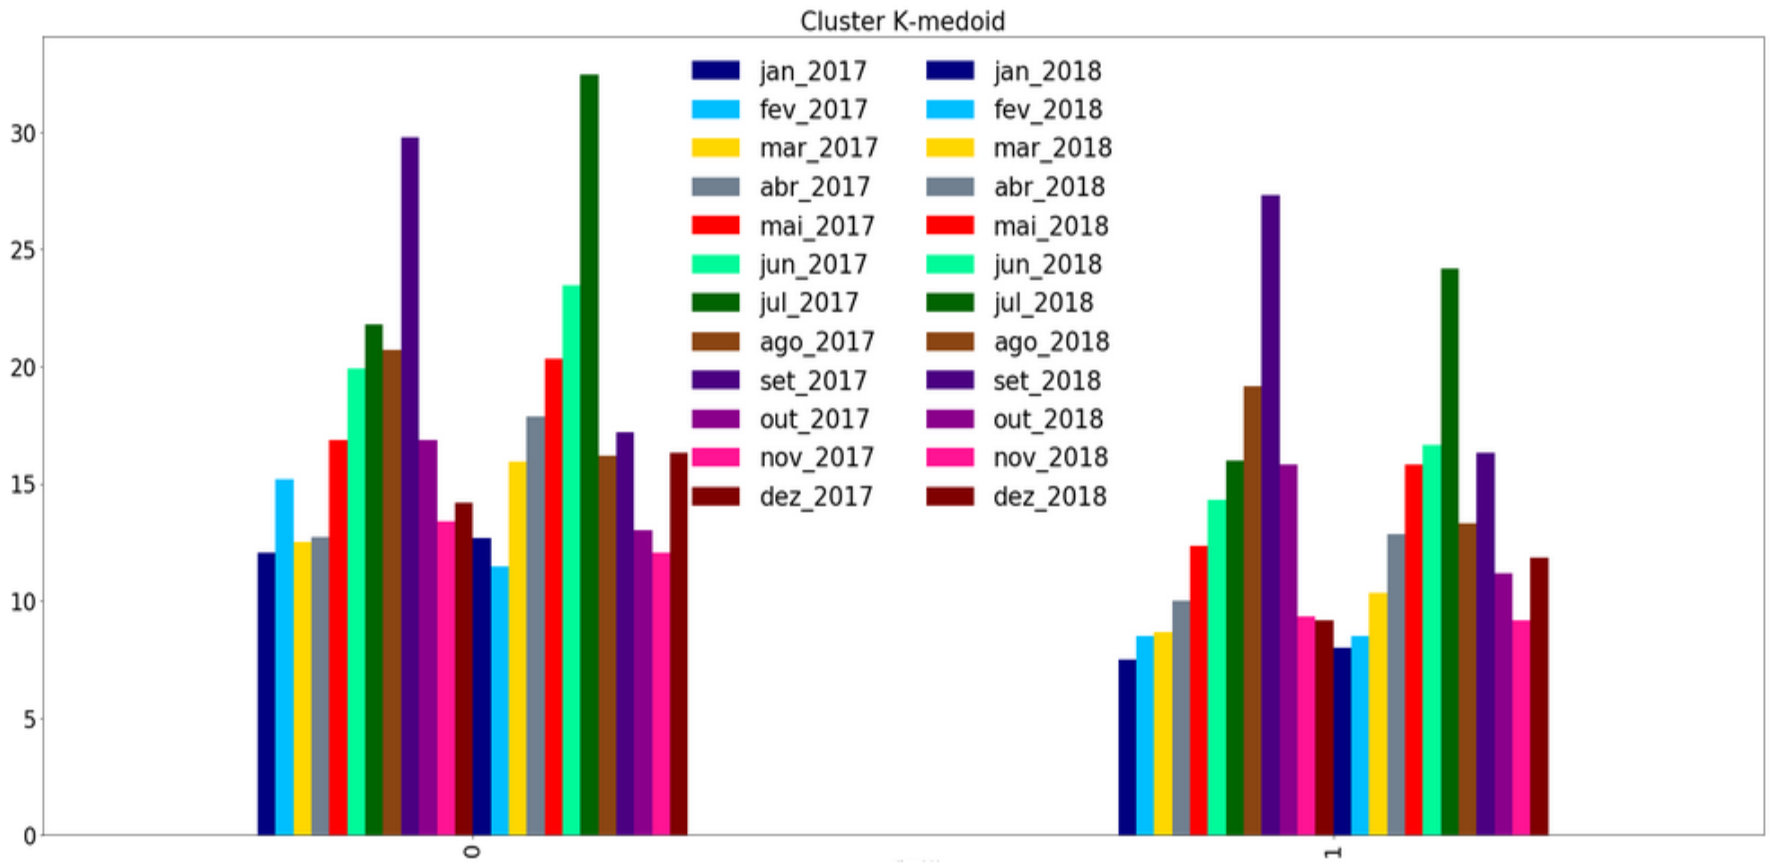

Referência OMS: 20µg/m³
2017: 15µg/m³
2018: 16µg/m³

Cluster 0

15 estações

Média anual global de 17,5µg/m³.

Cluster 1

6 estações

Média anual global de 13,2µg/m³.

Comportamento cíclico: semelhança na evolução de concentração da taxa e picos mensais, nos dois grupos, nos mesmos períodos – 2017 e 2018.

Esses ciclos podem estar relacionados com fenômenos meteorológicos que atuaram ao longo dos dois anos.

Resultados e Discussões

- Implementação: Linguagem *Python*
- Algoritmo *"Folium"*

Agrupamento

- ***Cluster 0:*** municípios da **região metropolitana** de São Paulo, mas **também do interior**, como Campinas. Fonte principal de poluentes a **queima de combustíveis por frota veicular e emissões industriais** mais intensas.
- ***Cluster 1:*** cidades (estações) com **menores taxas de concentração** estão localizadas no interior do estado e **mais distantes uma das outras**.

Cluster 0	*Cluster 1*
Parque D.Pedro II	Piracicaba
Santos-Ponta da Praia	Pico do Jaragua
Santana	S.Jose Campos-Jd.
Congonhas	Taubate
Ibirapuera	Ribeirao Preto
Cid.Universitária-USP-	São Jose do Rio Preto
Grajau-Parelheiros	
Pinheiros	
Osasco	
Guarulhos-Paço	
Itaim Paulista	
Marg.Tiete-Pte	
S.Bernardo-Centro	
Guarulhos-Pimentas	
Campinas-V.União	

Visualização por geolocalização dos *clusters* criados pelo algoritmo K-Medoids.

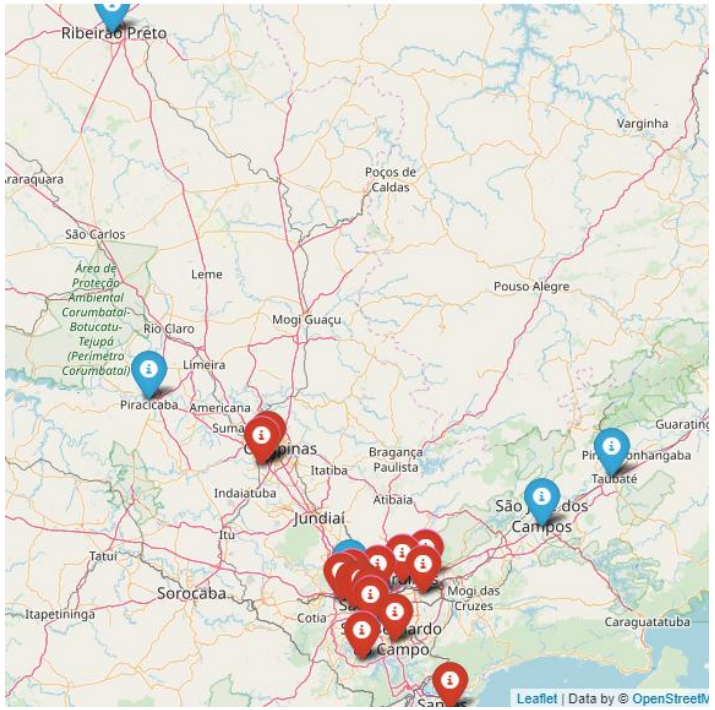

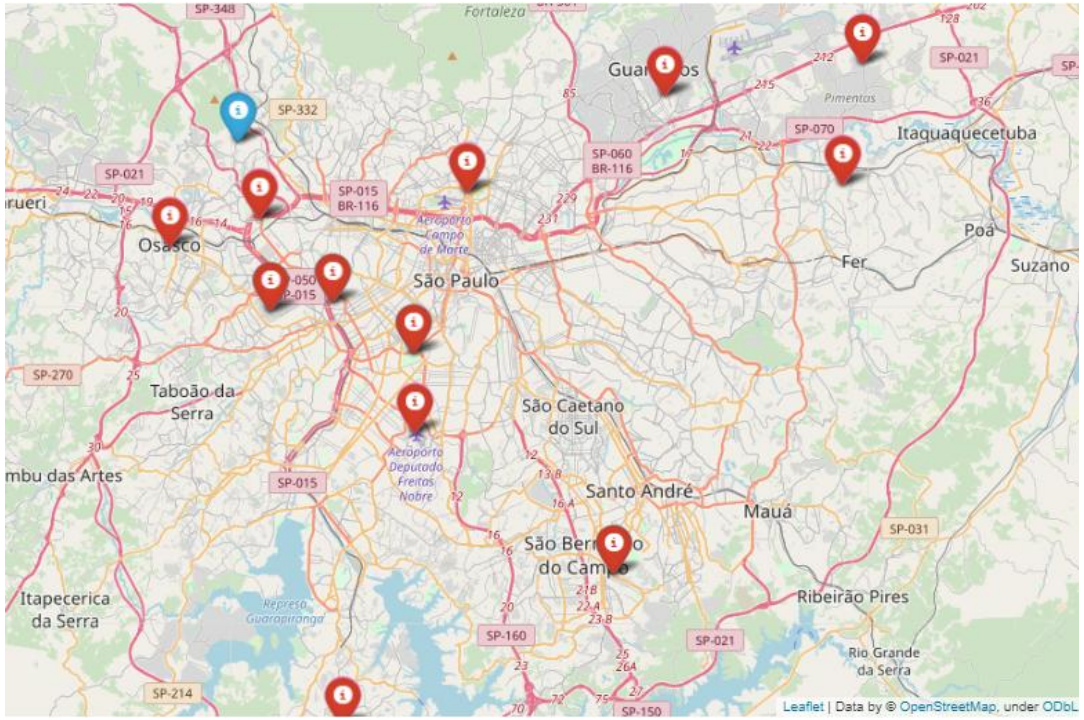

Resultados e Discussões

- **Médias Mensais por *Clusters* e diferenças nas concetrações do poluente entre os grupos**
- Mínimo de **1,0µg/m³** / Máximo de **8,3µg/m³**.

2017

Clusters	Jan	Fev	Mar	Abr	Mai	Jun	Jul	Ago	Set	Out	Nov	Dez
Grupo 0	12,1	15,2	12,5	12,7	16,9	19,9	21,8	20,7	29,8	16,9	13,4	14,2
Grupo 1	7,5	8,5	8,7	10,0	12,3	14,3	16,0	19,2	27,3	15,8	9,3	9,2
Diferença	4,6	6,7	3,9	2,7	4,5	5,6	5,8	1,6	2,5	1,0	4,1	5,0

2018

Clusters	Jan	Fev	Mar	Abr	Mai	Jun	Jul	Ago	Set	Out	Nov	Dez
Grupo 0	12,7	11,5	15,9	17,9	20,3	23,5	32,5	16,2	17,2	13,0	12,1	16,3
Grupo 1	8,0	8,5	10,3	12,8	15,8	16,7	24,2	13,	16,3	11,2	9,2	11,8
Diferença	4,7	3,0	5,6	5,0	4,5	6,8	8,3	2,9	0,9	1,8	2,9	4,5

Dados INPE: "Em setembro de 2017, as chuvas se concentraram em apenas dois dias no final do mês. Dessa forma, os totais mensais de precipitação pluviométrica, nos meses de julho e setembro, ficaram muito abaixo da média climatológica." (INPE, 2018)

Estudos feitos no Brasil mostram a influência do incremento de 5µg/m³ nas concentrações de MP2,5 implicando em aumentos entre 20% a 38% percentuais nos riscos de internação por complicações pulmonares. (CESAR et al., 2016)(MACHIN, 2018)

Análise por Regras de Associação para os meses: Setembro 2017 / Julho 2018

Mês de alta concentração de $MP_{2,5}$: Setembro/2017

- Primeira iteração:

Regra 1 :(Umidade do ar abaixo da média) → (CO–Acima da média)
confiança = 100%, suporte=85%

Regra 2: (Temperatura acima da média) → (CO –acima da média),
confiança = 100%, suporte=75%

Mês de alta concentração $MP_{2,5}$: Julho/2018

- Segunda iteração:

Regra 1: (Temperatura abaixo da média) → (Velocidade do vento abaixo da média), confiança = 100%, suporte=100%

Regra 2: (Umidade do ar abaixo da média) → (Velocidade do vento abaixo da média), confiança = 100%, suporte=87%

Regra 3: (CO –Acima da média, Velocidade do vento abaixo da média)→ (Temperatura abaixo da média), confiança = 100%, suporte=87%

Conclusão

- **Agrupamento:**

- Clusters com maiores concentrações e menores concentração de $MP_{2,5}$;
- Geolocalização;
- Comportamento Cíclico;
- Maiores concentração do Material Particulado fino no inverno (alta elevação em Setembro/2017 e Julho/2018)

- **Regras de Associação:**

- Relação de alta concentração de $MP_{2,5}$ com as variáveis meteorológicas.
- Associações identificadas: **Setembro/2017**: baixa umidade, CO com concentrações acima da média e temperaturas também acima da média.
- **Julho/2018:** Temperaturas abaixo da média e velocidade do vento abaixo da média.

Referências

[1] AUSTIN, E. et al. A framework to spatially cluster air pollution monitoring sites in US based on the PM2.5 composition. Environment International, v. 59, 2013.

[2] CARDOSO, K. M., PAULA, A., SANTOS, J. S., SANTOS, M. L. P. Use of Species of Urban Trees in Environmental Pollution Biomonitoring, 2017. , Revista Ciência Florestal, vol.27, no.2 .Santa Maria Apr./June 2017.

[3] CASTRO, Leonardo Nunes, FERRARI, Daniel Gomes. Introdução a Mineração de Dados, algoritmos e aplicações. São Paulo: Saraiva, 2016.

[4] CESAR ACG, NASCIMENTO LFC, MANTOVAN KCC, VIEIRA, LCP. Fine particulate matter estimated by mathematical model and hospitalizations for pneumonia and asthma in children. Revista Paulista de Pediatria 2016.

[5] CETESB. Relatório de Qualidade do Ar. 2018. Disponível em: <https://cetesb.sp.gov.br/ar/wp-content/uploads/sites/28/2018/05/ relatorio-qualidade-ar-2017.pdf>. Acesso em: 08 mai. 2019.

[6] DIMITRIOU, K. Upgrading the Estimation of Daily PM10 Concentrations Utilizing Prediction Variables Reecting Atmospheric Process. Aerosol and Air Quality Research, v. 16, 2016.

[7] HAN, J.; KAMBER, M. Data Mining: Concepts and Techniques. 2ª edição: Morgan Kaufmann, 2006.

[8] INPE. CPTEC. Boletins de Informações Climáticas do CPTEC/INPE. Infoclima, Ano 24, n. 1-12, 2017b. Disponível em: <http://infoclima1.cptec.inpe.br>. Acesso em: 08 mai. 2019.

Referências

[9]QUALAR. Qualidade do Ar. 2019. Disponível em: <https://cetesb.sp.gov.br/ar/qualar>. Acesso em: 08 mai. 2019.

[10] MACHIN, AB, NASCIMENTO, LFC. Efeitos da exposição a poluentes do ar na saúde das crianças de Cuiabá, Mato Grosso, Brasil. Cad. Saúde Pública, 2018.

[11] MARTINS, E. H.; NOGAROTTO, D. C.; MORTATTI, J.; POZZA, S. A. Chemical Composition of Rainwater in an Urban Area of the Southeast of Brazil. Atmospheric Pollution Research, Fator de Impacto (2017): 2,152, 2019, v. 10, p. 520-530.

[12] NOGAROTTO, Danilo Covaes. Avaliação de modelos de regressão de trajetórias para a previsão de poluentes atmosféricos – Limeira, SP : [s.n.], 2019.

[13] WHO - WORLD HEALTH ORGANIZATION. 9 out of 10 people worldwide breathe polluted air, but more countries are taking action. 2019. Disponível em: <https://www.who.int/news-room/detail/02-05-2018-9-out-of-10-people-worldwide-breathe-polluted-air-but-more-countries-are-taking-action>. Acesso em: 08 mai. 2019.

[14] YANAGI, Y. Estudo da influência do material particulado na incidência e mortalidade por câncer na cidade de São Paulo, 2010. 130f. Dissertação (Mestrado em Saúde Pública) – Programa de Pós-graduação em Saúde Pública da Faculdade de Saúde Pública, Universidade de São Paulo, São Paulo, 2010.