APLICAÇÃO DE ALGORITMOS DE APRENDIZADO DE MÁQUINA À ANÁLISE DE CONCENTRAÇÕES DE $MP_{2,5}$ EM CIDADES DO ESTADO DE SÃO PAULO

Application of machine learning algorithms to $MP_{2.5}$ concentration analysis in cities of São Paulo state

RESUMO

Dados de monitoramento da qualidade do ar são úteis em diferentes áreas de pesquisa e aplicações, como por exemplo, na relação da poluição do ar com problemas respiratórios e outros prejuízos à saúde. Dentre os principais poluentes atmosféricos estão: ozônio (O_3), dióxido de enxofre (SO_2), monóxido de carbono (CO), dióxido de nitrogênio (NO_2) e material particulado (MP). O MP é um dos principais objetos de estudos quando se pretende proteger as pessoas da exposição a poluentes. O trabalho corrente contribui com a análise da concentração do poluente $MP_{2,5}$, em 21 estações de monitoramento do estado de São Paulo, observadas pela CETESB - Companhia Ambiental do Estado de São Paulo. Foram utilizados algoritmos de aprendizado de máquina – agrupamento – para a separação automática de estações a partir de médias mensais de concentração de $MP_{2,5}$ nos anos de 2017 e 2018. Os grupos de estações com maiores índices encontrados do poluente foram os centros urbanos, com emissões por indústrias e veículos e, as estações com índices menores foram as localizadas mais ao interior do estado. Também houve a identificação de um comportamento cíclico nas variações do poluente nos dois anos para os dois grupos. Para os meses de maior concentração de $MP_{2,5}$ outra técnica de aprendizado de máquina foi aplicada – Regras de Associação – a fim de relacionar variáveis meteorológicas: temperatura do ar, umidade relativa do ar e velocidade do vento, às concentrações dos poluentes $MP_{2,5}$ e CO. Os resultados gerados podem ser úteis na análise do comportamento cíclico das concentrações de material particulado e suas relações com os fatores meteorológicos mais frequentes nos períodos de maior concentração do poluente. Isto pode contribuir para a geração de alertas para a comunidade, relacionado aos problemas de saúde que podem ser gerados.

Palavras-chave: Poluentes Atmosféricos; Agrupamentos; Regras de Associação; Qualidade do ar; Doenças respiratórias.

ABSTRACT

Air quality monitoring data are useful in different areas of research and applications with a focus on the relationship of air pollution with respiratory problems and other health hazards.

Among the main air pollutants are: Ozone (O_3), Sulfur Dioxide (SO_2), Carbon Monoxide (CO), Nitrogen Dioxide (NO_2) and Particulate Matter (PM). The PM is one of the main objects of study when it is intended to protect people from exposure to pollutants. This work contributes to the analysis of $MP_{2.5}$ pollution in 21 stations in the state of São Paulo, monitored by CETESB - Environmental Company of the State of São Paulo. Partitional grouping algorithms were used for the automatic separation of station from monthly averages of $MP_{2.5}$ concentration, in the years 2017 and 2018. The groups of station with the highest pollutant indices were urban centers with emissions by industries and vehicles and, the stations with the lowest indexes, were those located further inland. There was also the identification of a cyclical behavior in the pollutant variations in the two years for both groups.

For the months with the highest concentration of MP2.5, another machine learning technique was applied - Association Rules - in order to relate meteorological variables: air temperature (Temp), relative humidity (UR) and wind speed (VV) to the concentrations of pollutants $MP_{2.5}$ and carbon monoxide (CO).

The obtained results can be useful in the analysis of the cyclical behavior of the concentrations of particulate matter and their relationship with the most frequent meteorological factors in periods of greater concentration of the pollutant. This can contribute to the generation of alerts for the community, related to the health problems that can be generated.

Keywords: Air pollutants; Particulate Matter; Clustering; Association Rules; Air quality; Respiratory diseases.

INTRODUÇÃO

Na população mundial, nove em cada dez pessoas respiram ar poluído e contaminado, de acordo com o relatório anual da OMS - Organização Mundial da Saúde. Todos os anos morrem sete milhões de pessoas no mundo, por causas diretamente relacionadas com a poluição do ar e, mesmo assim, os níveis de contaminação permanecem elevados (WHO, 2019).

De acordo com a CETESB - Companhia Ambiental do Estado de São Paulo (CETESB, 2019) os principais poluentes atmosféricos legislados pelo CONAMA (Conselho Nacional do Meio Ambiente) são: Partículas Inaláveis (MP_{10}), Partículas Inaláveis Finas ($MP_{2,5}$), Monóxido de Carbono (CO), Dióxido de Nitrogênio (NO_2), Dióxido de Enxofre (SO_2), Ozônio (O_3), Partículas Totais em Suspensão (PTS), Fumaça (FMC) e Chumbo (Pb), sendo os três últimos monitorados apenas em situações específicas. Estudos associados à poluição na saúde (POLEZER et. al, 2018; MACHIN, 2018; SEINFELD e PANDIS 2016; SANT, A., NODARI e SALDANHA, 2016) comprovam que a exposição ao $MP_{2,5}$ pode causar problemas

respiratórios e até mesmo mortes prematuras, já que penetram profundamente no sistema respiratório, podendo alcançar os alvéolos pulmonares e corrente sanguínea.

O MP está relacionado com os impactos ao clima e meio ambiente, assim como com danos à saúde humana. Estas partículas podem ser sólidas ou líquidas que estão em suspensão na atmosfera, podendo ser geradas por diversas fontes, em diferentes tamanhos e composições diferentes (DIMITRIOU, 2016; ANDRADE et al., 2012; QUALAR, 2019). O MP é classificado por seu diâmetro aerodinâmico (d_a), sendo que os de diâmetro menor que 2,5 μm são classificados como $MP_{2,5}$ (material particulado inalável fino) e os de diâmetro entre 2,5 a 10 μm são nomeados como MP_{10} (material particulado inalável grosso). As fontes emissoras desses poluentes podem ser várias, como: veículos, indústrias, usinas e queimadas em geral. Variáveis meteorológicas interferem diretamente na concentração dos poluentes atmosféricos e fontes naturais como vulcões e poeiras que carregam substâncias tóxicas e cancerígenas ou que potencializam efeitos danosos ao meio ambiente e à saúde (YANAGI et al., 2012). É sabida a relação entre a concentração de $MP_{2,5}$ e variáveis meteorológicas como: temperatura do ar (TEMP), umidade relativa do ar (UR) e velocidade do vento (VV) que variam durante o ano, por isso, observamos que, no inverno, a qualidade do ar piora com relação à concentração de CO já que as condições meteorológicas nesta, estação, são mais desfavoráveis à sua dispersão (CETESB, 2019). O $MP_{2,5}$ por ser um poluente de menor diâmetro, consequentemente mais leve, com dispersão entre cidades por atividades industriais ou emissões resultantes de tráfego (NOGAROTTO, 2019).

Portanto, a interação entre as condições atmosféricas e as fontes de poluição define o nível de qualidade do ar, que por sua vez determina o surgimento de efeitos adversos da poluição do ar sobre as pessoas. Considerando este cenário, é importante a investigação do comportamento destas partículas, o que pode ser feito por meio de diversas técnicas de aprendizado de máquina. Pesquisas realizadas no Brasil e em outros países aplicando técnicas de aprendizado de máquina, tais como agrupamento, identificam regiões com padrões semelhantes de poluição do ar. No Brasil, os trabalhos de CESAR et al. (2016) e MACHIN (2018) mostram a influência do incremento de 5 μg/m³ nas concentrações de $MP_{2,5}$ implicando em aumentos entre 20% a 38% percentuais nos riscos de internação por complicações pulmonares. Nos EUA, uma pesquisa agrupou locais de acordo com níveis do índice $MP_{2,5}$ e obteve grupos por regiões e atividade industrial desenvolvida (AUSTIN et al., 2013); na China, estudos envolvendo 13 locais com similaridade de dados de concentração de $MP_{2,5}$ resultou em três grupos, dois demonstrando níveis semelhantes de atividades industriais e outro com atividades agrícolas e turísticas (HUANG et al., 2015).

Outro algoritmo bastante utilizado para análise de dados no contexto de poluição são as chamadas regras de associação (NEIROTTI et. al, 2014; AGRAWAL e SRIKANT, 1994). O trabalho de (DU e VARDE, 2016), utiliza este algoritmo para identificar relações entre material particulado, poluição e tráfego. Já (SOUZA e RABELO, 2016) aplicou regras de associação para identificar conjunto de variáveis que frequentemente ocorrem em conjunto, sendo eles poluentes do ar e problemas respiratórios.

Analisando a literatura é possível constatar a importância de se obter novos conhecimentos sobre o $MP_{2,5}$, sendo assim, este trabalho pretende analisar a base de dados de monitoramento da qualidade do ar fornecida pela CETESB, nos anos de 2017 e 2018. Tal análise será realizada aplicando técnicas de aprendizado de máquina em duas frentes: (i) utilização do algoritmo de Agrupamento Particional (*K-medoids*) para a formação de grupos, com base nas concentrações de $MP_{2,5}$ de 21 estações no estado de São Paulo; e (ii) aplicação do algoritmo Apriori de regras de associação na descoberta de possíveis associações entre os fatores meteorológicos que têm influência no aumento na concentração de $MP_{2,5}$ e CO.

METODOLOGIA

A metodologia utilizada neste trabalho será apresentada de acordo as seguintes partes: i) apresentação do local de onde os dados atmosféricos foram coletados e como foram pré-processados para que pudessem ser utilizados pelos algoritmos de aprendizado de máquina; ii) explicação do algoritmo de agrupamento e do algoritmo de regras de associação e suas respectivas métricas de validação.

Local de estudo

O diagnóstico da qualidade do ar no estado de São Paulo ocorre a partir das redes de monitoramento da CETESB (Figura 1), que informam as concentrações por grupos de poluente e garantem a conformidade com os níveis que não representam riscos significativos para a saúde humana. A avaliação é efetuada considerando os padrões estaduais de qualidade do ar estabelecidos pelo Decreto Estadual n° 59.113, de 23/04/2013 e pelo CONAMA por meio da Resolução nº 491 de 19/11/2018 (CONAMA, 2019). Ambos determinam limites de emissão dos poluentes com metas intermediárias para que a poluição atmosférica seja reduzida gradativamente, até que atinjam os padrões finais da OMS.

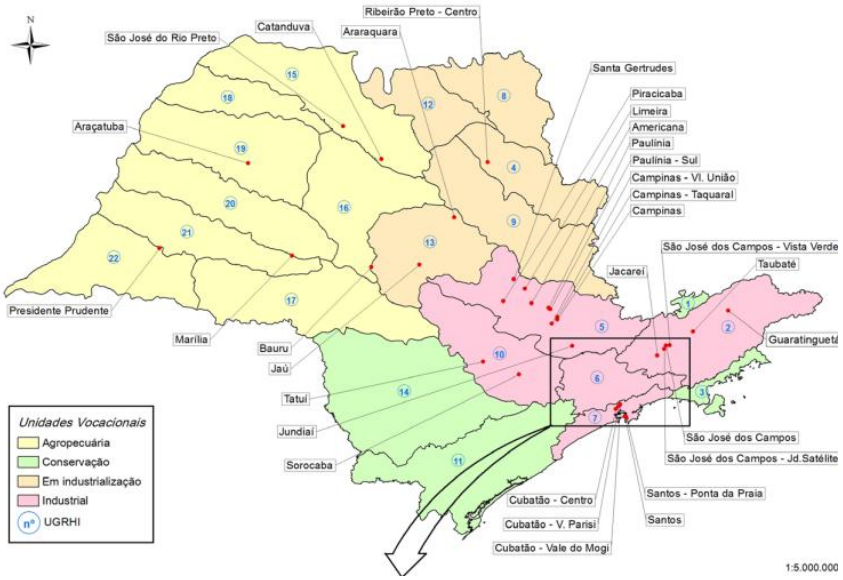

Fonte: CETESB, 2018

Figura 1 - Mapa de localização das redes automáticas de monitoramento no estado de São Paulo.

Para a análise do comportamento do poluente em diferentes áreas no estado de São Paulo, foram obtidos dados de todas as cidades que possuem estações com monitoramento de $MP_{2,5}$. Ao todo são vinte e uma estações, conforme a tabela1.

Tabela 1 – Cidades e estações com monitoramento de $MP_{2,5}$ no estado de São Paulo.

Cidade	Estação
Campinas	Vila União
Piracicaba	Campus FUMEP
Serra da Cantareira	Pico do Jaraguá
São José dos Campos	Jd. Satélite
São Bernardo do Campo	Centro
Taubaté	Parque Municipal “Eng. César A. C. Varejão”
Ribeirão Preto	Parque Ecológico Maurílio Biaggi
São José do Rio Preto	Campo Atletismo Eldorado
Santos	Ponta da Praia
São Paulo	Itaim Paulista
	Santana
	Congonhas
	Ibirapuera
	Cidade Universitária (USP)
	Parque D. Pedro II
	Pinheiros
	Marginal Tietê (Ponte dos Remédios)
	Grajau (Parelheiros)
Osasco	Vila Quitaúna
Guarulhos	Paço Municipal
Guarulhos	Pimentas

Base de Dados e Pré-processamento

A primeira base de dados foi obtida pelo site da CETESB, na plataforma Qualidade do Ar (QUALAR, 2019), fornecida pelas estações automáticas de monitoramento. Foram utilizados os dados de concentração de médias mensais de $MP_{2,5}$ referentes ao período de 01/01/2017 a 31/12/2018. Esses dados geraram um *dataset* com 21 registros (estações) e 24 colunas (meses) representando o período de dois anos.

Nesta primeira base, foi realizado o pré-processamento que identificou os meses com valores faltantes no monitoramento de $MP_{2,5}$. Para realizar o estudo das séries temporais, é necessário que todos os valores estejam preenchidos (CASTRO et al., 2016). Nos casos onde havia valores faltantes em um determinado mês, foi considerado o valor do mesmo mês, porém, do ano posterior ou anterior, disponível no período de 2017 e 2018. É visto que os meses de medição tendem a ser semelhantes de um ano ao outro, por exemplo, a medição do mês de janeiro de 2017 é similar ao de janeiro de 2018 (NOGAROTTO et al., 2019; PINTO, REISEN e MONTE, 2018).

Além disso, foi realizada a normalização de dados, sendo um procedimento de pré-processamento de dados cujo objetivo é padronizar os valores dos atributos de forma que todos fiquem dentro de um intervalo específico, ou distribuído em torno de sua média de acordo com seu desvio padrão. Os dados da base coletada foram submetidos ao processo de normalização utilizando a técnica z-*score* (HAN e KAMBER, 2006).

Para a construção da segunda base de dados, foram verificadas as estações que monitoram $MP_{2,5}$ e que também disponibilizam médias mensais das seguintes variáveis meteorológicas: Umidade Relativa do ar (UR), Temperatura (TEMP), Velocidade do Vento (VV), além da emissão de CO disponibilizados na CETESB (QUALAR, 2019) para os anos de 2017 e 2018. Das 21 estações cujos dados foram obtidos para a primeira base, 7 estações atendiam a este novo critério (Tabela 1).

Para este novo *dataset*, todos os dados necessitam ser categóricos, pois é uma restrição do algoritmo *Apriori*. Dessa forma, cada valor de média mensal foi categorizado de acordo com duas categorias: inferior ou superior ao valor médio anual de sua respectiva variável meteorológica ou emissão de CO. A Tabela 2 representa a base no mês de julho de 2018.

Tabela 2 – Exemplo da representação da base de dados, relacionando as estações monitoradas por $MP_{2,5}$ aos parâmetros CO, UR, TEMP e VV, ano de 2018.

	Estação	Jul_2018_CO	Jul_2018_TEMP	Jul_2018_UR	Jul_2018_VV
0	Parque D. Pedro II	Superior a Média	Inferior a Média	Inferior a Média	Inferior a Média
1	Pinheiros	Superior a Máxima	Inferior a Média	Inferior a Média	Inferior a Média
2	Marg. Tietê-Pte	Superior a Média	Inferior a Média	Inferior a Média	Inferior a Média
3	S. Bernardo-Centro	Superior a Média	Inferior a Média	Superior a Média	Inferior a Média
4	Guarulhos-Pimentas	Superior a Média	Inferior a Média	Inferior a Média	Inferior a Média
5	S. José campos - Jd	Superior a Média	Inferior a Média	Inferior a Média	Inferior a Média
6	Taubaté	Superior a Média	Inferior a Média	Inferior a Média	Inferior a Média
7	Ribeirão Preto	Superior a Média	Inferior a Média	Inferior a Média	Inferior a Média

Fonte: autoria própria.

Os algoritmos aplicados neste trabalho seguem a abordagem não supervisionada de aprendizado de máquina, dividida em duas etapas: (i) aplicação do algoritmo de Agrupamento Particional (*K-medoids*) e (ii) Regras de Associação (*Apriori*). Nas próximas seções há a discussão a respeito destes algoritmos.

Técnica de agrupamento de dados

Os algoritmos de agrupamento podem ser particionais e hierárquicos. Dentro do grupo de algoritmos particionais os mais comuns são: *K-means* e *K-medoids* (JIN e HAN, 2017). O algoritmo *K-medoids* usa objetos da base como centro dos grupos, denominados medoides, os quais têm a menor dissimilaridade média a todos os outros objetos do grupo. No caso do *K-means*, os centros dos grupos são calculados de acordo com o valor médio dos objetos daquele grupo. Nesse caso, valores discrepantes da base podem influenciar a formação dos grupos, uma vez que contribuem para o cálculo dos valores centrais de cada grupo. Esse tipo de problema não acontece no algoritmo *k-medoids* uma vez que os medoides correspondem a amostras reais dos dados e não médias (HAN e KAMBER, 2006). Ambos os algoritmos (*K-means* e *K-medoid)* foram implementados na linguagem *Python*, utilizando as bibliotecas "*scikit-learn*" e "*pyclustering*", de código aberto, específicas para o aprendizado de máquina (PEDREGOSA, F. et al., 2011).

Para avaliar a qualidade do agrupamento entre os algoritmos *K-medoids* e *K-means* foi utilizada a medida do coeficiente de silhueta (KAUFMAN & ROUSSEEUW, 2005) aos resultados obtidos por cada algoritmo. Este coeficiente mede a robustez dos agrupamentos, ajudando a selecionar o número de grupos, considerando a similaridade interna e

dissimilaridade externa entre eles, ou seja, combina a coesão (mede o quão bem um elemento está dentro de um grupo) e a separação (mede o quanto os grupos estão separados entre si).

O valor médio do coeficiente deve estar entre -1 e 1, representando o quão bem os grupos foram formados. Os valores ideais são os positivos, com coeficiente de silhueta próximo de 1. A Equação (1) representa o cálculo médio da Silhueta.

$$S_p = \sum_{1}^{n} \frac{s(x_i)}{n} \tag{1}$$

sendo o valor individual do coeficiente de silhueta do elemento x_i dado por $s(x_i)$, obtido pela Equação (2):

$$s(x_i) = \frac{(b(x_i) - a(x_i))}{\max\{a(x_i), b(x_i)\}} \tag{2}$$

e os valores $a(x_i)$ e $b(x_i)$ correspondem, respectivamente, à distância média entre x_i e todos os objetos de seu grupo e à distância média x_i a um outro grupo ao qual x_i não pertença.

O coeficiente de silhueta foi a métrica de avaliação escolhida também para determinar qual dos dois algoritmos (*K-means e K-medoids*) seria utilizado neste trabalho. Logo, para realizar esta avaliação foi utilizada a base de dados de médias mensais de $MP_{2,5}$ e aplicados os dois algoritmos. O que apresentou o melhor resultado de silhueta foi adotado para o agrupamento das estações. Esse experimento é apresentado na seção Resultados.

Regras de associação

O algoritmo *Apriori* de Regras de Associação tem o objetivo de encontrar relacionamentos frequentes nos conjuntos de dados, isto é, gerar regras do tipo X → Y, para as quais X e Y são itens que fazem parte deste conjunto de dados (AGRAWAL e SRIKANT, 1994). Para análise dos possíveis padrões encontrados nos meses de maior concentração de $MP_{2,5}$ foi aplicado o algoritmo de Regras de Associação *Apriori*, a fim de encontrar um subconjunto de parâmetros frequentes relacionados à base de $MP_{2,5}$.

O algoritmo *Apriori* vasculha, a partir de uma base transacional, quais itens estão relacionados. Considera duas medidas de relevância e validação de regras: suporte e confiança. Dada a regra X → Y, o suporte (ou cobertura da regra) representa a porcentagem de transações da base de dados que contêm os itens de X e Y, indicando a relevância da mesma (CASTRO et al., 2016). A confiança ou acurácia de uma regra, por sua vez, corresponde ao número de regras em que o consequente de uma regra aparece em transações em que o antecedente também é observado, ou seja, é a probabilidade condicional P(Y|X) de que dado o consequente X da regra,

o antecedente Y também acontece (MUELLER, 1995). Neste trabalho, o algoritmo *Apriori* foi implementado na linguagem *Python*, utilizando a biblioteca "*mlxtend*".

RESULTADOS E DISCUSSÃO

Para o experimento de escolha do algoritmo de agrupamento, foi utilizado como critério de decisão o valor do coeficiente de silhueta, por se tratar de uma medida de qualidade para toda estrutura do agrupamento. Além disso, o coeficiente de silhueta também foi utilizado na escolha do número de grupos (k), para isso foram testados 20 diferentes grupos relacionado ao número de cidades.

Após 100 execuções do algoritmo *k-medoids*, aplicado à base de dados de concentração de médias mensais de $MP_{2,5}$ nos anos de 2017 e 2018, o coeficiente de silhueta médio encontrado foi de 0,32 e, para o mesmo critério mas utilizando o algoritmo *k-means*, o valor médio foi de 0,26. Considerando que quanto mais próximo a 1 o valor estiver, melhor será a qualidade do agrupamento, o algoritmo *k-medoids* foi selecionado por apresentar melhor valor médio de silhueta.

Na Figura 2 é possível verificar a relação entre o valor do coeficiente de silhueta correspondente ao número *k* de grupos. Verifica-se que o melhor valor corresponde ao valor de *k* = 2. Dessa forma, o algoritmo *k-medoids* foi aplicado para obtenção de dois grupos do conjunto de estações do estado de São Paulo, com monitoramento de $MP_{2,5}$, e posteriormente analisados os resultados do agrupamento.

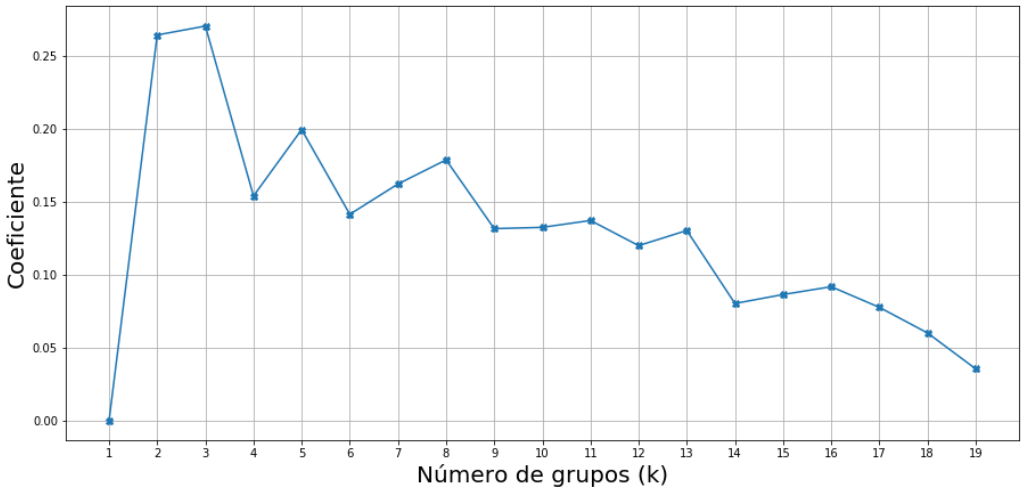

Figura 2 – Número de *k* grupos por valor do coeficiente de silhueta, obtido a partir do algoritmo *K-medoids*.

Como resultado da aplicação do algoritmo *K-medoids* aos dados, com valor de $k = 2$, as estações foram divididas nos grupos 1 e 2, apresentados na Tabela 3.

Tabela 3 – Relação das estações de monitoramento por grupo.

Grupo 1	Grupo 2
Santos – Ponta da Praia	Piracicaba
São Paulo – Santana	Serra da Cantareira – Pico do Jaraguá
São Paulo – Congonhas	São José dos Campos – Jd. Satélite
São Paulo – Ibirapuera	Taubaté
São Paulo – Cidade Universitária (USP)	Ribeirão Preto
São Paulo – Grajau (Parelheiros)	São José do Rio Preto
São Paulo – Pinheiros	
Osasco	
Guarulhos – Paço Municipal	
Guarulhos – Pimentas	
São Paulo – Itaim Paulista	
São Paulo – Marginal Tietê (Pte. Remédios)	
São Bernardo do Campo – Centro	
Campinas – Vila União	
São Paulo – Parque D. Pedro II	

Fonte: autoria própria

No período analisado, para todas as estações monitoradas as concentrações médias anuais de $MP_{2,5}$ foram de 15 μg/m³, em 2017 e 16 μg/m³, em 2018, ficando próximas ao limite anual estabelecido pela OMS de 20 μg/m³. Analisando cada grupo, podemos verificar diferenças:

- **Grupo 1:** 15 estações localizadas em sua maioria em metrópoles, mais especificamente em cidades com taxa média anual global de $MP_{2,5}$ de 17,5 μg/m³.
- **Grupo 2:** 6 estações localizadas em cidades com índices relativamente menores, com taxa média anual global de $MP_{2,5}$ de 13,2 μg/m³.

Nota-se na Figura 3 que, no comportamento dos grupos 1 e 2, nos anos de 2017 e 2018, predominam índices maiores de concentração de $MP_{2,5}$ no Grupo 1. Observando-se os grupos 1 e 2, percebe-se que, para os primeiros doze meses em 2017, o mês de maior concentração é setembro, e para 2018, o mês de maior concentração é julho. Observa-se também uma tendência temporal semelhante, na evolução de concentração da taxa do poluente e picos mensais, para os dois grupos, nos mesmos períodos dos anos de 2017 e 2018, sugerindo um padrão recorrente nos dois anos. Esses ciclos podem estar relacionados a fenômenos meteorológicos que atuaram ao longo do período, que coincidem com os dados dos relatórios anuais da CETESB (CETESB,

2019) que foram analisados com o algoritmo de regras de associação (*Apriori*) e relatados a seguir.

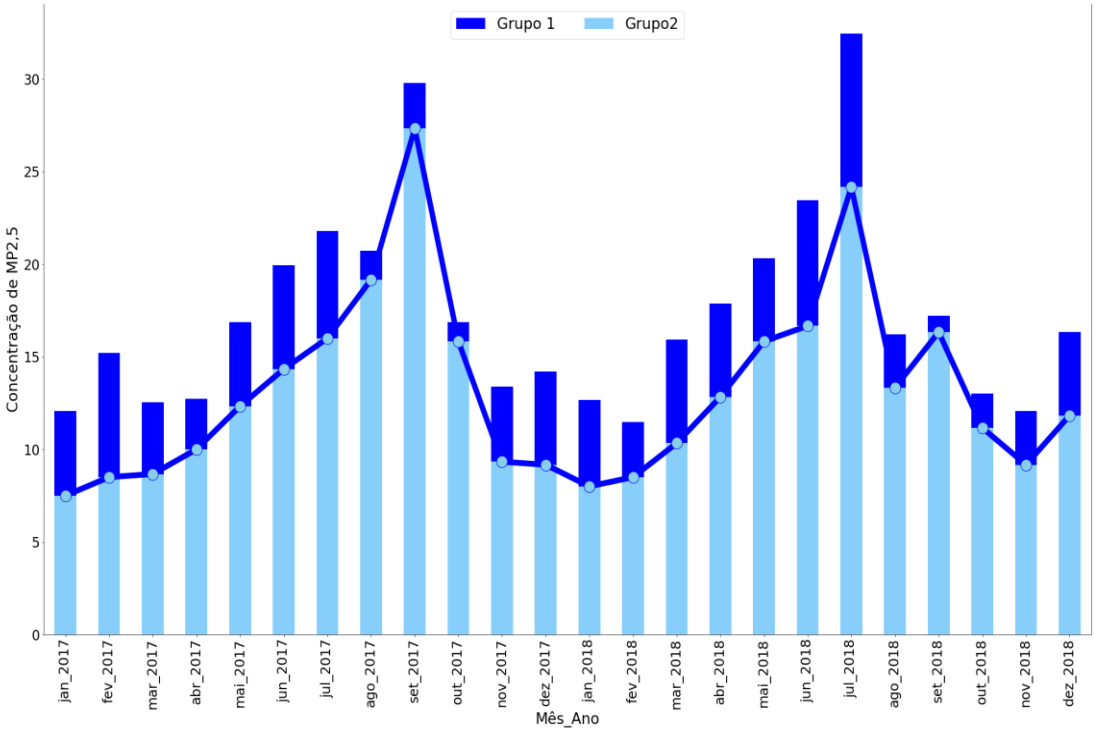

Figura 3 – Médias mensais das concentrações (µg/m³) de $MP_{2.5}$ das cidades do estado de SP, nos anos de 2017 e 2018.

Para melhor projeção da proximidade física entre as estações, de acordo com sua localização, foi gerada a Figura 4, que apresenta o mapeamento de cada grupo. Os grupos 1 e 2 foram identificados pelas cores vermelha e azul, respectivamente, nas Figuras 4a e 4b.

A análise no mapa evidencia que a maioria das estações com monitoramento para o poluente $MP_{2,5}$, com maior concentração, está associada a municípios da região metropolitana de São Paulo e cidades do interior, como Campinas, nas quais a fonte principal de poluentes é dada pela queima de combustíveis por frota veicular e emissões industriais mais intensas (CARDOSO et al., 2017; HUANG et al., 2015; YANAGI et al., 2012). As estações com menores taxas de concentração estão localizadas no interior do estado e mais distantes uma das outras.

Figura 4(a)

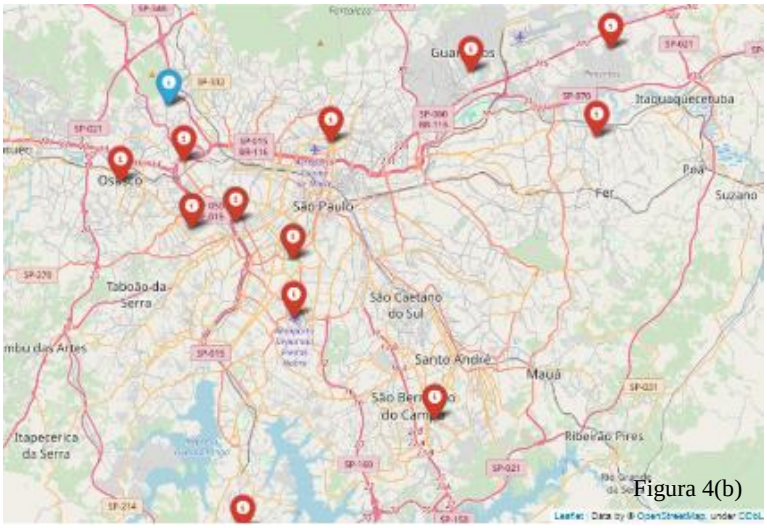

Figura 4(b)

Figura 4 – (a) Visualização por geolocalização dos grupos, criados pelo algoritmo *K-medoids*, e (b) proximidade dos elementos do Grupo 1 no mapa. Na cor vermelha o Grupo 1 e em azul o Grupo 2.

A variação média mensal de $MP_{2,5}$ dos grupos 1 e 2 demonstra que há grande diferença nas concentrações do poluente entre os dois grupos, como retrata a Tabela 4, com mínimo de 1,0 µg/m³ e máximo de 8,3 µg/m³ de diferença nas concentrações. No ano de 2017, percebe-se que o nível aumenta de maio a outubro, com pico em setembro, de proximadamente 29,8 µg/m³. Da mesma forma, no ano de 2018, de março a setembro, com pico no mês de julho, de 32,4 µg/m³.

Tabela 4 – Médias Mensais de $MP_{2,5}$ por grupos de estações e diferenças entre os grupos (G1 – G2 em µg/m³), em 2017 e 2018. Os meses demarcados são os períodos de maior concentração do poluente, nos dois anos, com destaque para o mês de pico em setembro/2017 e julho/2018.

Clusters	Jan	Fev	Mar	Abr	Mai	Jun	Jul	Ago	Set	Out	Nov	Dez
	2017											
Grupo 1 (G1)	12,1	15,2	12,5	12,7	16,9	19,9	21,8	20,7	**29,8**	16,9	13,4	14,2
Grupo 2 (G2)	7,5	8,5	8,7	10,0	12,3	14,3	16,0	19,2	**27,3**	15,8	9,3	9,2
(G1 – G2)	4,6	6,7	3,9	2,7	4,5	5,6	5,8	1,6	**2,5**	1,0	4,1	5,0
	2018											
Grupo 1 (G1)	12,7	11,5	15,9	17,9	20,3	23,5	32,5	16,2	17,2	13,0	12,1	16,3
Grupo 2 (G2)	8,0	8,5	10,3	12,8	15,8	16,7	24,2	13,	16,3	11,2	9,2	11,8
(G1 – G2)	4,7	3,0	5,6	5,0	4,5	6,8	8,3	2,9	0,9	1,8	2,9	4,5

Fonte: autoria própria

Estudos comprovam que há uma relação entre a concentração de $MP_{2,5}$ com a variação de fatores meteorológicos tais como: TEMP, redução da UR e VV, aumentando riscos relacionados à saúde (INPE, 2019; CETESB, 2018). Os trabalhos (SANTOS et al., 2016; SANTOS et al., 2019) confirmam que há diferença significativa entre a concentração do $MP_{2,5}$

nos períodos secos e chuvosos, assim como, associação entre os parâmetros meteorológicos e a concentração de MP.

Para avaliar tal relação, foi coletado da base transacional (contendo os valores de concentração de $MP_{2,5}$ de cada estação e o comportamento das variáveis meteorológicas) os meses de maiores picos, identificados na Figura 3, ou seja, o mês de setembro de 2017 e o mês de julho de 2018, a fim de submeter ao algoritmo de regras de associação *Apriori* de forma a descobrir quais fatores foram mais frequentes nos dois períodos e como esses fatores meteorológicos se relacionaram.

Na primeira execução do *Apriori*, utilizando os dados relativos a setembro de 2017, foram obtidas 9 regras, sendo 7 repetidas, isto é, regras que possuíam o mesmo significado. Isso acontece, pois, o algoritmo analisa todas as possibilidades entre os itens. Portanto, as duas principais regras são mostradas na Tabela 5. O suporte corresponde a freqüência com que ocorrem os padrões em toda a base de dados, indicando a porcentagem que as transações ocorrem. Enquanto que a confiança mede a força das regras, que garante que as transações satisfaçam o antecedente das regras, também satisfaçam o conseqüente das regras.

Tabela 5. Regras com suporte superior a 75% para setembro de 2017.

Regras (Antecedente → Consequente)	**Suporte**	**Confiança**
Regra 1. (UR inferior à média) → (CO acima da média)	85%	100%
Regra 2. (TEMP acima da média) → (CO acima da média)	75%	100%

É possível concluir, a partir da Regra 1, que quando o $MP_{2,5}$ está com alta concentração, a UR inferior à média e CO acima da média ocorrem juntos com frequência de 85% na base. Esta regra informa também que quando a concentração de CO está acima da média, com certeza de 100% há a ocorrência de UR inferior à média.

Para a Regra 2, nos picos de concentração de $MP_{2,5}$, os fatores que ocorrem juntos com frequência de 75% é o CO acima da média e a TEMP acima da média. Com relação à confiança, quando o CO acima da média ocorre com certeza de 100% há ocorrência de temperatura acima da média.

Na segunda execução do *Apriori* foram utilizados os dados relativos ao mês de julho de 2018 e foram obtidas 44 regras, sendo escolhidas para análise as três, não repetidas, com maior suporte e confiança (Tabela 6).

Tabela 6. Regras selecionadas com suporte superior a 75% para julho de 2018.

Regra	Suporte	Confiança
Regra 1. TEMP abaixo da média → VV abaixo da média	100%	100%
Regra 2. UR inferior à média → VV abaixo da média	87%	100%
Regra 3: CO acima da média e VV abaixo da média → TEMP abaixo da média	87%	100%

Para alta concentração de $MP_{2,5}$ que tivemos em julho de 2018, a Regra 1 identifica os seguintes fatores: TEMP abaixo da média e VV abaixo da média ocorrem juntos com frequência de 100% na base, para a Regra2 a frequência de ocorrência dos dois fatores é de 87% e a probabilidade de VV baixa dada a ocorrência de UR inferior à média é de 100%. Para a Regra 3, três fatores aparecem juntos com frequência de 87% e confiança de 100%, indicando que toda vez que a TEMP fica predominantemente mais fria, a concentração de CO aumenta e a VV fica abaixo da média, sinalizando que em estações mais frias há o aumento da concentração de CO estimulado pela baixa dispersão deste poluente.

Considerando que os períodos de maior concentração de $MP_{2,5}$ são os que apresentam o maior risco à população e que os fatores meteorológicos têm influência no aumento da concentração do poluente, as regras apresentadas acima poderiam dar indicativos de alerta para o aumento da concentração do poluente.

Dessa forma, podemos concluir que, quando medições apresentam baixa de UR, TEMP acima da média e concentrações acima da média de CO, podem ser indicativos de possibilidade de aumento de concentração de $MP_{2,5.}$ Os resultados também indicam que, quando há TEMP abaixo da média, VV mais amenas, UR abaixo da média e concentração de CO acima da média, existe a possibilidade de aumento de $MP_{2,5}$.

CONCLUSÕES

A análise de Material Particulado Fino foi realizada através da aplicação, primeiramente, de um algoritmo de agrupamento, que dividiu os valores de medições de concentrações de $MP_{2,5}$ de 21 estações monitoradas, distribuídos em 24 meses nos anos 2017 e 2018.

Os experimentos apontaram que a conformação de dois grupos é a mais adequada. Os resultados apresentados mostram que as estações pertencentes aos grupos identificados possuem características específicas que levam a diferentes índices de poluição. Os municípios da região metropolitana de São Paulo se destacam como os que possuem maior concentração

de $MP_{2,5}$, mas também apontam cidades monitoradas no interior, com emissões industriais e veiculares, formando um dos grupos. Já as estações alocadas ao outro grupo, menos poluídas, estão localizadas mais no interior do estado, distantes das fontes de poluição, tais como emissões de veículos, processos industriais e queimadas em geral.

Houve a formação de dois grupos bastante característicos com variações de concentração do poluente que seguiram um padrão ao longo de cada ano. O padrão que pôde ser visualizado no estudo temporal, com um comportamento cíclico que se repetiu em todo período, em ambos os grupos. Há uma incidência maior de $MP_{2,5}$ no inverno, que apresentou picos (setembro/2017 e julho/2018) em meses críticos quando as variáveis meteorológicas (TEMP, UR, VV) e alta na emissão de CO contribuem para o aumento de concentração do poluente.

A partir daí, um outro algoritmo foi aplicado a dados meteorológicos relativos aos períodos de setembro de 2017 e julho de 2018, a fim de encontrar associações entre os fatores meteorológicos mencionados anteriormente nos períodos de maior concentração de $MP_{2,5}$. Os resultados mostraram que, no mês de setembro de 2017, os fatores meteorológicos predominantes foram: a baixa UR, CO com concentrações acima da média e TEMP também acima da média. Já em julho de 2018, as regras mostraram que principalmente as TEMP abaixo da média e VV mais amenas são os principais fatores meteorológicos que ocorreram no período de maior média de concentração do poluente.

As regras encontradas podem ser úteis na criação de sinais de alerta para possíveis aumentos de concentração de material particulado, uma vez que a concentração do poluente sofre a influência de tais fatores.

AGRADECIMENTOS

O presente trabalho foi realizado com apoio da Coordenação de Aperfeiçoamento de Pessoal de Nível Superior - Brasil (CAPES) – Código de Financiamento 001.

REFERÊNCIAS

AGRAWAL, R., SRIKANT, R. (1994) Fast Algorithms for Mining Association Rules in Large Databases. In Proceedings of the 20th International Conference on Very Large Data Bases (VLDB '94), pp. 487 – 499.

ALBUQUERQUE, T.T.A.; ANDRADE, M.F. (2005) Distribuições de tamanho, composição química e identificação das fontes do aerossol atmosférico de São Paulo: um estudo de caso para o inverno de 2003. 2005. Universidade de São Paulo, São Paulo, 2005.

ANDRADE, M., MIRANDA, R.M., FORNARO, A. et al. Vehicle emissions and PM2.5 mass concentrations in six Brazilian cities. Air Quality, Atmosphere and Health, v. 5, 79–88 (2012). <https://doi.org/10.1007/s11869-010-0104-5>.

AUSTIN, E., COULL, B. A., ZANOBETTI, A., & KOUTRAKIS, P. (2013). A framework to spatially cluster air pollution monitoring sites in US based on the PM2.5 composition. Environment International, 59, 244–254. <https://doi.org/10.1016/j.envint.2013.06.003>

CARDOSO, K. M., PAULA, A., SANTOS, J. S., SANTOS, M. L. P. (2017). Uso de espécies da arborização urbana no biomonitoramento de poluição ambiental. Ciência Florestal, 27(2), 535–547. <https://doi.org/10.5902/1980509827734>

CASTRO, L. N., FERRARI, D. G. (2016) Introdução a Mineração de Dados. Conceitos Básicos, Algoritmos e Aplicações. São Paulo: Saraiva, 2016. 351p.

CÉSAR, A. C. G., NASCIMENTO, L. F. C., MANTOVANI, K. C. C., & VIEIRA, L. C. P. (2016). Fine particulate matter estimated by mathematical model and hospitalizations for pneumonia and asthma in children. Revista Paulista de Pediatria, 34(1), 18–23. <https://doi.org/10.1016/j.rppede.2015.12.005>

CETESB (2019) Relatório de Qualidade do Ar no estado de São Paulo. Governo do Estado de São Paulo – Secretaria do Meio Ambiente. Companhia Ambiental do Estado de São Paulo. Disponível em: <https://cetesb.sp.gov.br/ar/wp-content/uploads/sites/28/2019/05/Relat%C3%B3rio-de-Qualidade-do-Ar-2017.pdf >. Acesso em: 08 mai. 2019.

CONAMA (2019) Conselho Nacional do Meio Ambiente. Ministério do Meio Ambiente – Conselho Nacional do Meio Ambiente. Resolução N. 491, de 19 de novembro de 2018. Disponível em: <http://www2.mma.gov.br/port/conama/legiabre.cfm?codlegi=740>. Acesso em: 10 jun. 2019.

DIMITRIOU, K. (2016). Upgrading the estimation of daily PM10 concentrations utilizing prediction variables reflecting atmospheric processes. Aerosol and Air Quality Research, 16(9), 2245–2254. <https://doi.org/10.4209/aaqr.2016.05.0214>

DU, X., & VARDE, A. S. (2016). Mining PM2.5 and traffic conditions for air quality. 2016 7th International Conference on Information and Communication Systems, ICICS 2016, (April 2016), 33–38. <https://doi.org/10.1109/IACS.2016.7476082>

HAN, J., & KAMBER, M. (2006) Data Mining: Concepts and Techniques. (2nd ed.). San Francisco: Morgan Kaufmann Publishers, 2006.

HUANG, P., ZHANG, J., TANG, Y., & LIU, L. (2015). Spatial and temporal distribution of PM2.5 pollution in Xi'an city, China. International Journal of Environmental Research and Public Health, 12(6), 6608–6625. <https://doi.org/10.3390/ijerph120606608>

INPE (2019) Instituo Nacional de Pesquisas Espaciais. Boletins de Informações Climáticas do CPTEC/INPE. Infoclima, Ano 24, n. 1-12, 2017b. Disponível em: <http://infoclima1.cptec.inpe.br>. Acesso em: 08 mai. 2019.

JIN, X., & HAN, J. (2017). K-Medoids Clustering. In C. Sammut & G. I. Webb (Eds.), Encyclopedia of Machine Learning and Data Mining (pp. 697–700). <https://doi.org/10.1007/978-1-4899-7687-1_432>

KAUFMAN, L. & ROUSSEEUW, P. J. (2005). Finding Groups in Data – An Introduction to Cluster Analysis, Wiley Series in Probability and Statistics, NY.

MACHIN, A. B., & NASCIMENTO, L. F. C. (2018). Efeitos da exposição a poluentes do ar na saúde das crianças de Cuiabá, Mato Grosso, Brasil. Cadernos de Saúde Publica, 34(3), 1–9. <https://doi.org/10.1590/0102-311X00006617>

MARTINS, E. H.; NOGAROTTO, D. C.; MORTATTI, J.; POZZA, S. A. (2019) Chemical Composition of Rainwater in an Urban Area of the Southeast of Brazil. Atmospheric Pollution Research, Fator de Impacto (2017): 2,152, 2019, v. 10, p. 520-530.

MUELLER, A (1995). Fast sequential and parallel algorithms for association rule mining: a comparison. Thesis (M.S.). Dept. of Computer Science, University of Maryland at College Park, August 1995.

NEIROTTI, P., MARCO, A., CAGLIANO, A. C., MANGANO, G., & SCORRANO, F. (2014). Current trends in smart city initiatives: Some stylised facts. Cities, 38(September 2018), 25–36. <https://doi.org/10.1016/j.cities.2013.12.010>

NOGAROTTO, D. C. (2019) Avaliação de modelos de regressão de trajetórias para a previsão de poluentes atmosféricos – Limeira, SP: [s.n.], 2019.

NOGAROTTO, D. C., ROSSI, N. M., POZZA, S. A. (2019) Um novo método de preenchimento de dados faltantes aplicado a séries temporais de concentração de MP10. R. Tecnol. Soc., Curitiba, v. 15, n. 37, p. 275-296, jul./set. 2019. Disponível em: <https://periodicos.utfpr.edu.br/rts/article/view/8594>. Acesso em: 20/02/2020.

PEDREGOSA, F. et al. (2011). Scikit-learn: Machine learning in python. Journal of Machine Learning Research, v. 12, p. 2825–2830, 2011. Disponível em: <http://www.jmlr.org/papers/v12/pedregosa11a.html>

PINTO, W. P., REISEN, V. A., MONTE, E. Z. (2018) Previsão da concentração de material particulado inalável, na Região da Grande Vitória, ES, Brasil, utilizando o modelo SARIMAX. Engenharia Sanitária e Ambiental, v. 23, n. 2, p. 307-318, 2018

POLEZER, G., TADANO, Y. S., SIQUEIRA, H. V., GODOI, A. F. L., YAMAMOTO, C. I., de ANDRÉ, P. A., GODOI, R. H. M. (2018). Assessing the impact of PM2.5 on respiratory disease using artificial neural networks. Environmental Pollution, 235, 394–403. <https://doi.org/10.1016/j.envpol.2017.12.111>

QUALAR (2019) Qualidade do Ar, CETESB – Dados meteorológicos. Disponível em: <https://cetesb.sp.gov.br/ar/qualar>. Acesso em: 08 mai. 2019.

QUEIROZ, P. G. M., JACOMINO, V. M. F., MENEZES, M. A. B. C. (2007) Composição elementar do material particulado presente no aerossol atmosférico do município de Sete Lagoas, Minas Gerais. Química NOVA, v. 30, n. 5, p.1233-1239, 2007

SANT, A., NODARI, A. N. A., & SALDANHA, C. B. (2016). Episódios Críticos de Poluição Atmosférica bo Município de Porto Alegre / Rs Analysis Of Weather Conditions During Critical Episodes Of Atmospheric Pollution In The City Of Porto Alegre / RS.

SANTOS, F.S. et al (2019) Avaliação da influência das condições meteorológicas na concentração de material particulado fino (MP2,5) em Belo Horizonte, MG. Eng. Sanit. Ambient. [online]. 2019, vol.24, n.2, pp.371-381.

SANTOS, T.C.; CARVALHO, V.S.B; REBOITA, M.S. (2016) Avaliação da influência das condições meteorológicas em dias com altas concentrações de material particulado na Região Metropolitana do Rio de Janeiro. Revista de Engenharia Sanitária e Ambiental, Rio de Janeiro, v.21, n.2, 307-313, 2016.

SEINFELD, J. H., PANDIS, Spyros N. (2016) Atmospheric Chemistry and Physics from Air Pollution to Climate Change. (3rd ed.), Wiley: New York, 2016.

SOUZA, F. T., & RABELO, W. S. (2016). A data mining approach to study the air pollution induced by urban phenomena and the association with respiratory diseases. Proceedings - International Conference on Natural Computation, 2016-Janua, 1045–1050. <https://doi.org/10.1109/ICNC.2015.7378136>

WHO (2019) World Health Organization. Nine out of ten people worldwide breathe polluted air, but more countries are taking action. Disponível em: <https://www.who.int/news-room/detail/02-05-2018-9-out-of-10-people-worldwide-breathe-polluted-air-but-more-countries-are-taking-action>. Acesso em: 08 mai. 2019.

YANAGI, Y., ASSUNÇÃO, J. V., BARROZO, L. V. (2012). The impact of atmospheric particulate matter on cancer incidence and mortality in the city of São Paulo, Brazil Influência do material particulado atmosférico na incidência e mortalidade por câncer no Município. Cad. Saúde pública, Rio de Janeiro, 28(9): 1737–1748, set, 2012.

ZAKI, M., PARTHASARATHY, S., Li, W., OGIHARA, M. (1997). Evaluation of sampling for data mining of association rules. In 7th International Workshop on Research Issues in Data Engineering. RIDE'97 - Birmingham, UK.